

Um Harness de IA para Resolução de Perguntas em Linguagem Natural: Adaptando o Ralph Wiggum Loop Além do Desenvolvimento de Software

Hugo Emílio Nomura, Pedro Henrique Correia de Oliveira, Pedro Henrique Satoru Lima Takahashi, Vitor Monteiro Vianna

Ciência da Computação – Centro Universitário FEI, campus São Paulo

unifhnomura@fei.edu.br, unifpoliveira@fei.edu.br, unifptakahashi@fei.edu.br, unievvianna@fei.edu.br

Orientador: Charles Henrique Porto Ferreira

Departamento de Ciência da Computação, Centro Universitário FEI

cferreira@fei.edu.br

Resumo: Os *Large Language Models* (LLMs), embora sejam em essência geradores probabilísticos de texto, alcançam ganhos expressivos de desempenho quando o processo de inferência é estruturado por *harnesses* que incorporam planejamento, decomposição de tarefas e ciclos iterativos de refinamento. Entretanto, arquiteturas que preservam o histórico completo de execução em uma única janela de contexto introduzem degradação progressiva da qualidade das respostas conforme o contexto cresce, fenômeno denominado *context rot*, que compromete a confiabilidade dos resultados em execuções longas.

Este trabalho propõe a adaptação do *Ralph Wiggum Loop*, paradigma de orquestração originalmente concebido para fluxos focados em desenvolvimento e engenharia de software e que traz soluções para mitigar problemas de *context rot*, para um fluxo de resolução generalista, focado em responder perguntas em linguagem natural. A hipótese é que essa estrutura melhora a qualidade das respostas em relação à inferência singular, e essa hipótese é avaliada por meio da criação de *benchmarks* estabelecidos usando os *datasets* MMLU e GPQA, comparando chamadas diretas ao modelo com execuções mediadas pelo *harness* proposto, utilizando modelos da família Llama 3.1 com diferentes quantidades de parâmetros. A acurácia, medida pela correspondência entre a alternativa selecionada pelo sistema e o gabarito oficial, é adotada como métrica principal.

Palavras-chaves: *Large Language Models* (LLMs). Ralph Wiggum Loop. Sistemas Compostos de IA. Engenharia de Prompt. Decaimento de Contexto (*context rot*).

1. Introdução

Os *Large Language Models* (LLMs) consolidaram-se como o núcleo de uma nova geração de sistemas capazes de executar tarefas complexas de processamento de linguagem natural, incluindo geração de texto, resolução de problemas, planejamento intermediário e suporte à tomada de decisão. Apesar dessas capacidades, os modelos que servem como base para esses sistemas continuam sendo, em essência, geradores probabilísticos de *tokens*, operando a partir de uma entrada de texto e retornando como saída outro texto, como discutem Brown et al. [2] e Zhao et al. [24]. Nesse contexto, parte significativa da evolução recente dos sistemas baseados em LLMs passou a ocorrer não apenas nos próprios modelos, mas também nas estruturas responsáveis por organizar sua utilização prática. Trabalhos recentes, como os de Lee et al. [10], afirmam que “*The performance of large language model (LLM) systems depends not only on model weights, but also on their harness: the code that determines what information to store, retrieve, and present to the model*”, evidenciando o papel dos chamados *harnesses* na ampliação das capacidades desses sistemas. Ferramentas modernas, como o ChatGPT, incorporam tais mecanismos para adicionar camadas de coordenação, decomposição de tarefas, validação intermediária e orquestração de múltiplas inferências, permitindo que o modelo execute fluxos signi-

ficativamente mais sofisticados do que uma única chamada linear de entrada e saída, como mostram Zaharia et al. [23] e Wang et al. [19].

Abordagens baseadas em uma única chamada ao modelo, nas quais toda a resposta é produzida em uma única etapa de inferência, apresentam limitações importantes em tarefas que exigem raciocínio complexo, múltiplas etapas de decisão ou validações intermediárias. Como resposta a esse problema, diferentes linhas de pesquisa passaram a explorar fluxos estruturados de *thinking*, nos quais o processo de inferência é explicitamente decomposto em etapas sucessivas de raciocínio, planejamento, execução e refinamento. Wei et al. [20], ao proporem o *Chain-of-Thought*, Yao et al. [22], com o *Tree of Thoughts*, e Zhou et al. [25], com a técnica de *Least-to-Most*, demonstram que a decomposição explícita do raciocínio favorece significativamente a resolução de tarefas complexas. De maneira semelhante, Yao et al. [21] propõem o *ReAct* ao combinar raciocínio e ações iterativas, enquanto Shinn et al. [16] com *Reflexion*, Chen et al. [4] com *Self-Debugging* e Madaan et al. [12] com *Self-Refine* exploram ciclos sucessivos de avaliação, crítica e refinamento da própria resposta gerada. Em conjunto, esses trabalhos indicam que ganhos de desempenho não dependem exclusivamente do tamanho do modelo ou da quantidade de *tokens* gerados, mas também da maneira

como o processo de inferência é estruturado, coordenado e validado ao longo da execução.

Apesar dos ganhos observados nessas arquiteturas iterativas compostas por agentes, ciclos de reflexão ou *pipelines* sucessivos, tais abordagens também introduzem novos desafios relacionados ao gerenciamento do contexto acumulado durante a inferência [7], [11]. Em muitos desses sistemas, o histórico completo de interações permanece armazenado na janela de contexto ao longo de toda a execução como mecanismo de preservação da continuidade do raciocínio. Embora essa estratégia favoreça rastreabilidade e coerência entre etapas intermediárias, ela também aumenta progressivamente a dificuldade de recuperação de informações relevantes conforme o contexto cresce. Liu et al. [11], por exemplo, demonstram que ocorre perda de desempenho em tarefas que exigem localizar informações relevantes em sequências extensas. Trabalhos recentes também passaram a discutir fenômenos associados à degradação progressiva do contexto em execuções longas, incluindo compressão implícita de informações, perda de relevância contextual e aumento de inconsistências ao longo da inferência. Esses efeitos vêm sendo frequentemente associados, ao conceito de *context rot*, termo utilizado por Hong et al. [7] para descrever a degradação gradual da qualidade das respostas conforme o volume de contexto acumulado aumenta.

Além do avanço acadêmico dessas abordagens, a indústria de engenharia de software também passou a investir intensamente em arquiteturas de *deep thinking* e em *harnesses* especializados para ampliar a capacidade operacional de LLMs em tarefas complexas de desenvolvimento. Ferramentas recentes, como Claude Code, GPT Codex, OpenCLI e Devin, exemplificam essa tendência ao combinar planejamento, decomposição de tarefas, validação iterativa e execução coordenada de múltiplas inferências. Nesse contexto, uma das abordagens que ganhou notoriedade foi o *Ralph Wiggum Loop*, desenvolvido por Geoffrey Huntley [5] no contexto de engenharia de software. Em sua formulação original, entretanto, o modelo não foi concebido para cenários generalistas, mas especificamente para fluxos de desenvolvimento baseados em conceitos próprios da engenharia de software, como definição de funcionalidades, requisitos, critérios de aceite e integração com sistemas de versionamento, como o Git. Ainda assim, sua estrutura apresenta dois princípios centrais relevantes para os problemas discutidos na literatura de LLMs: (i) a decomposição do processo em tarefas independentes, reduzindo a necessidade de reaproveitamento contínuo do contexto entre etapas e, portanto, mitigando o *context rot*, e (ii) a execução iterativa de cada tarefa até que critérios mínimos de qualidade sejam satisfatoriamente atingidos.

Este trabalho parte de três premissas consolidadas na literatura: que abordagens de *thinking* podem melhorar a qualidade das respostas de LLMs em cenários específicos, como os de tarefas complexas [20], [22]; que tais abordagens introduzem problemas associados ao crescimento excessivo do contexto acumulado, fenômeno descrito como *context rot* [7]; e que Huntley [5], ao conceber o *Ralph Wiggum Loop* para fluxos de engenharia de software, ofe-

rece princípios estruturais capazes de mitigar o problema de *context rot* por meio de decomposição de tarefas e isolamento contextual entre etapas. A partir dessas premissas, propõe-se a adaptação do *Ralph Wiggum Loop* para um contexto generalista de resolução de tarefas em linguagem natural a partir de um *prompt* de entrada fornecido pelo usuário. Diferentemente da proposta original, centrada em desenvolvimento de software, definições de funcionalidades, critérios de aceite baseados em requisitos funcionais e integração com ferramentas de versionamento (como Git), a adaptação proposta investiga se, ao adaptar a estrutura do *Ralph Wiggum Loop* a um fluxo completo de *thinking* aplicável à resolução de perguntas gerais e à exploração de problemas diversos e de diferentes complexidades, também haverá melhora na qualidade dessas respostas quando comparadas a uma única etapa de inferência.

Para avaliar essa hipótese de maneira objetiva, reproduzível e quantitativa, o trabalho compara diretamente duas estratégias de inferência: (i) uma chamada tradicional a um modelo de LLM, na qual toda a resposta é produzida em uma única etapa de inferência; e (ii) uma execução mediada pelo *harness* proposto, que adapta o *Ralph Wiggum Loop* para cenários generalistas. O objetivo experimental é medir em que magnitude a aplicação desse fluxo estruturado de *thinking* melhora a qualidade das respostas em relação à inferência singular tradicional. Para permitir essa quantificação, os experimentos utilizam *benchmarks* compostos por questões e respostas para mensurar ganhos em arquiteturas de raciocínio e orquestração de LLMs, abordagem descrita em trabalhos como o de Yao et al. [21], que propõe o *ReAct*, e o de Wang et al. [19]. Os experimentos são conduzidos com diferentes modelos da família Llama 3.1, com diferentes quantidades de parâmetros utilizados na execução do modelo, representando distintos níveis de complexidade computacional, e avaliados por meio dos *datasets* MMLU [6] e GPQA [15], sendo a acurácia, medida pela quantidade de acertos entre a alternativa selecionada pelo sistema de LLM e o gabarito oficial.

II. Referencial Bibliografico

Esta seção apresenta os conceitos fundamentais necessários para a compreensão do trabalho proposto. São definidos os termos técnicos centrais utilizados ao longo do texto, descritas as principais estratégias de raciocínio e refinamento aplicadas a modelos de linguagem, e introduzido o paradigma de orquestração adotado neste trabalho.

Os *Large Language Models* (LLMs) [2] são amplamente consolidados como geradores probabilísticos de *tokens* baseados na arquitetura *Transformer* [17]. Um detalhamento teórico e histórico aprofundado sobre o funcionamento desses modelos de linguagem pode ser encontrado no levantamento conduzido por Zhao et al. [24], constituindo a base primordial sobre a qual este trabalho é desenvolvido.

A. Modelos de Linguagem e a Arquitetura de Harness

A evolução recente na aplicação de LLMs migrou de chamadas diretas e lineares para o uso de estruturas de orquestração mais robustas. Na prática, a organização

dessas interações é viabilizada por meio de um *harness*, termo que se refere à estrutura lógica e às regras de orquestração que envolvem um modelo de linguagem para guiar seu processo de inferência, funcionando como uma camada de coordenação entre o *prompt* inicial do usuário e a saída do modelo [19], [23]. Um *harness* pode incluir etapas de planejamento, decomposição de tarefas, validação intermediária e composição de respostas finais. Variações na arquitetura do *harness* podem causar impactos significativos no desempenho do sistema como um todo, mesmo quando o modelo base permanece o mesmo.

Esse conceito está diretamente relacionado à noção de *Sistemas Compostos de IA*, definida por Zaharia et al. [23] como arquiteturas que resolvem tarefas de inteligência artificial por meio de múltiplos componentes que interagem entre si, incluindo chamadas a modelos, recuperadores de informação e ferramentas externas. Segundo essa perspectiva, os ganhos mais significativos em aplicações de IA contemporâneas passaram a depender da engenharia de sistemas que combinam componentes especializados em fluxos coordenados, em vez de se apoiarem unicamente no aumento de escala dos modelos base [23].

Essa tendência se manifesta em ferramentas industriais que utilizam LLMs integrados a *harnesses* especializados para tarefas de engenharia e automação. Exemplos incluem o Claude Code [1], interface de linha de comando voltada ao desenvolvimento assistido por IA; o GPT Codex [3], otimizado para geração e compreensão de código; e o OpenCLI [14], voltado à automação de comandos de terminal. Essas ferramentas demonstram como a combinação de planejamento, decomposição de tarefas e validação iterativa expande a capacidade computacional útil dos modelos base.

B. Estratégias de Raciocínio e Refinamento

A literatura demonstra que a qualidade da inferência de um LLM pode ser melhorada de forma significativa quando o processo é estruturado em fases [20], [22]. O método *Chain-of-Thought*, proposto por Wei et al. [20], e sua generalização *Tree of Thoughts*, proposta por Yao et al. [22], mostraram a importância de induzir o modelo a explicitar passos intermediários de raciocínio. Abordagens como o *ReAct*, proposto por Yao et al. [21], ampliaram esse princípio ao combinar o raciocínio interno do modelo com a capacidade de invocar ferramentas externas, permitindo corrigir alucinações [8] por meio de observações diretas do ambiente.

De forma complementar, pipelines baseados em ciclos de *feedback* iterativo também apresentam ganhos consistentes. O framework *Reflexion*, proposto por Shinn et al. [16], introduziu ciclos nos quais o modelo atua como seu próprio crítico, revisando saídas com base em reforço verbal externo. Chen et al. [4], com a abordagem de *Self-Debugging*, demonstraram que LLMs podem identificar e corrigir seus próprios erros quando guiados de forma sistemática. Na mesma direção, Madaan et al. [12], com o método *Self-Refine*, consolidaram a eficácia do refinamento iterativo ao demonstrar que modelos podem gerar *feedback* crítico sobre suas próprias respostas e utilizá-lo para melhorar as

saídas de forma sucessiva, contornando limitações da geração em uma única etapa. Essa capacidade de autocrítica e revisão contínua constitui uma premissa fundamental para a proposta deste trabalho.

Além dessas abordagens, métodos focados na decomposição de tarefas complexas também contribuem para a redução de erros lógicos e omissões. Técnicas de *prompting* baseadas em decomposição, como as de Zhou et al. [25] com *Least-to-Most*, Khot et al. [9] com *Decomposed Prompting* e Wang et al. [18] com *Plan-and-Solve*, sustentam que separar o planejamento da execução e dividir problemas em subproblemas menores melhora o desempenho do modelo, especialmente quando combinado com mecanismos de validação intermediária.

C. Degradação de Contexto

Embora as técnicas apresentadas nas subseções anteriores tenham demonstrado eficácia individual, muitas delas dependem do acúmulo contínuo de estado em uma única janela de contexto, o que pode agravar problemas de degradação à medida que o histórico cresce. Liu et al. [11] demonstraram empiricamente que LLMs apresentam perda significativa de desempenho quando precisam recuperar informações relevantes posicionadas no meio de sequências longas, fenômeno descrito como “perdidos no meio” (*lost in the middle*).

Na prática, esse comportamento se manifesta de diversas formas: compressão implícita de informações, perda de relevância contextual, aumento de inconsistências e maior incidência de alucinações em execuções prolongadas [11], [24]. A literatura contemporânea frequentemente associa esse conjunto de efeitos ao conceito de *context rot*, referindo-se à degradação progressiva da qualidade das respostas conforme o contexto acumula ruído, redundâncias e informações que competem pela atenção do modelo [11].

D. O Ralph Wiggum Loop

Diante dos problemas de degradação de contexto, Huntley [5] propôs o *Ralph Wiggum Loop* na comunidade de engenharia de software como um paradigma de orquestração que aborda diretamente essa limitação. O paradigma parte de um conjunto de requisitos fornecidos como entrada e os decompõe em histórias de usuário, conceito consolidado na disciplina de engenharia de software. Cada história é tratada de forma atômica: o modelo implementa uma solução, executa testes e verifica se os critérios de aceite foram satisfeitos; caso contrário, o ciclo se repete até que a história seja concluída com êxito. Ao término de cada história, seus resultados não são carregados diretamente para a execução seguinte, evitando o acúmulo progressivo de estado que caracteriza arquiteturas tradicionais de agentes.

Um aspecto central dessa abordagem é o princípio de *Fresh Context*, descrito por Huntley [5]: ao iniciar cada nova história, o contexto de execução é completamente reinicializado. Antes de qualquer instrução sobre a nova história, os aprendizados gerais extraídos das histórias anteriores são injetados como primeira entrada nesse novo contexto, de forma estruturada e explícita. Dessa maneira, o paradigma preserva o conhecimento relevante acumulado




Figura 1. Ralph Wiggum Loop original.

sem herdar o ruído, as redundâncias e as informações obsoletas que degradam progressivamente a qualidade das respostas em execuções longas, mitigando ativamente o fenômeno de *context rot* [7].

Em sua formulação original, o *Ralph Wiggum Loop* foi concebido especificamente para fluxos de engenharia de software, com etapas voltadas à definição de funcionalidades, requisitos, critérios de aceite e integração com sistemas de versionamento como Git. Ainda assim, seus princípios de execução *stateless* e validação iterativa apresentam relevância direta para os problemas discutidos na literatura de LLMs. A validação acadêmica dessa abordagem foi reforçada pelo estudo de McComb et al. [13], que avaliou o impacto de agentes baseados no *Ralph Wiggum Loop* na resolução de problemas complexos de design de engenharia, confirmando a eficácia do paradigma *stateless* em contextos que exigem raciocínio estruturado e iterativo. Este trabalho se apoia nesses fundamentos para justificar o uso do paradigma, adaptando sua orquestração para a resolução de questões de propósito geral em múltiplos domínios do conhecimento.

III. Metodologia

A adaptação do *Ralph Wiggum Loop* para um contexto generalista de resolução de perguntas em linguagem natural exige ajustes estruturais em relação à formulação original, que foi concebida exclusivamente para fluxos de engenharia de software. A Figura 2 apresenta uma visão geral do fluxo proposto, que preserva os princípios centrais do paradigma original, representado na Figura 1.

Em linhas gerais, propomos uma conversão do conceito de histórias de usuário para tarefas, o que nos permite manter um fluxo muito próximo do original, contendo as etapas de “Planejamento” e “Execução em Loop”. Entretanto, passa a ser necessário considerar a criação de um retorno ao usuário, algo que não constitui uma preocupação no *Ralph Wiggum Loop* original. Dessa forma, incorporamos uma nova fase após o fluxo de execução, denominada “Criação da Resposta Final”, que contém toda a lógica necessária para agrupar os resultados produzidos pelas tarefas anteriores em uma

resposta que apresente o conteúdo e o formato esperados pelo usuário.

Para ilustrar concretamente cada etapa do fluxo, adota-se ao longo desta seção o seguinte *input* de referência:

Exemplo

Qual dos seguintes números é simultaneamente primo, par e maior que 2?

- A) 2
- B) 4
- C) 6
- D) Nenhuma das anteriores

Ao longo da descrição de cada fase, são apresentadas expressões que indicam quais informações compõem a entrada submetida ao modelo e qual saída é esperada. As nomenclaturas adotadas nessas expressões, como “Pergunta do usuário” ou “Template A.1”, representam os componentes lógicos necessários para montar o *prompt* de cada fase. O termo “Pergunta do usuário” refere-se ao *input* original fornecido ao sistema. Os termos na forma “Template X” referem-se a *prompts* fixos de instrução, cuja função é orientar o modelo sobre o que deve fazer naquela etapa específica. Já os termos na forma “Resultado Fase X” referem-se à saída produzida pelo modelo em uma etapa anterior, que pode ser reutilizada como entrada em etapas seguintes. Essas expressões não descrevem uma implementação concreta, mas sim a organização conceitual das informações que devem ser reunidas para que cada etapa do fluxo cumpra sua função.

A. Planejamento

O planejamento é o início de todo o fluxo, compreendendo duas etapas que preparam toda a estrutura de execução: a definição dos critérios que a resposta final deverá respeitar e a decomposição da pergunta em tarefas autônomas e verificáveis.




Figura 2. Visão geral do *Ralph Wiggum Loop* adaptado para resolução de perguntas em linguagem natural.

A.1 Definição dos critérios de aceite gerais

Essa etapa representa uma adição em relação ao paradigma original. No contexto de engenharia de software, cada tarefa concluída resultava em um *commit* que preservava o progresso diretamente no repositório, de modo que, ao término de todas as histórias de usuário, o produto final já estava pronto. No fluxo adaptado, entretanto, a conclusão de todas as tarefas não produz automaticamente uma saída utilizável: após todas as tarefas serem concluídas, é necessário construir uma resposta final que consolide os resultados gerados. Os critérios de aceite gerais definem as regras que essa resposta deverá respeitar, abrangendo aspectos como o idioma a ser utilizado, o formato de apresentação esperado e os tópicos-chave que devem constar no conteúdo final.

A execução desta etapa envolve a associação da pergunta do usuário com instruções estruturadas, representadas pelo Template A.1. Este gabarito orienta o modelo a analisar o enunciado recebido e produzir as diretrizes gerais que a resposta final precisará satisfazer. Especificamente, as instruções orientam o modelo a identificar o idioma de resposta adequado, a estrutura ideal do formato de saída (como seleção de alternativas ou desenvolvimento textual) e os termos e restrições obrigatórios definidos no enunciado. A relação de entrada e saída que formaliza essa transformação de prompts é descrita na expressão (1):

$$\text{Pergunta do usuário} + \text{Template A.1} \rightarrow \text{Resultado Fase A.1} \quad (1)$$

Nesta expressão, “Pergunta do usuário” representa o

enunciado inicial e as opções de escolha inseridas no sistema, enquanto “Template A.1” constitui o prompt fixo de instrução que orienta a análise. O “Resultado Fase A.1” corresponde à lista final de critérios de aceite gerais que deverão ser satisfeitos para que a resposta final seja homologada.

Os critérios de aceite estruturados gerados no Resultado Fase A.1 são persistidos localmente (em disco ou em memória) para posterior validação global na fase de Criação da Resposta Final.

Exemplo

Considerando o *input* de referência, o modelo deveria retornar uma lista de critérios como os seguintes.

Saída esperada do modelo:

“A pergunta deve ser respondida em Português do Brasil.”

“Responda somente a alternativa, sem conter explicações adicionais.”

“Garanta que o valor encontrado ao final corresponde a uma das alternativas fornecidas.”

A.2 Quebra em tarefas de objetivo único com critérios de aceite individuais

A segunda etapa do planejamento é responsável por quebrar a pergunta do usuário em pequenas tarefas autônomas. Cada tarefa precisa ter pelo menos um critério de aceite, isto é, uma condição que define o conteúdo esperado para que a tarefa possa ser considerada concluída. A ideia

central é criar tarefas que gerem insumos capazes de, em conjunto, sustentar a construção da resposta final.

Esta etapa é operacionalizada ao submeter a pergunta do usuário juntamente com o Template A.2, cuja finalidade é instruir o modelo a realizar a decomposição em tarefas de responsabilidade única. O template orienta a caracterização detalhada de cada tarefa (como as respectivas entradas e saídas esperadas), deixando explícito que o contexto não será compartilhado diretamente entre as iterações subsequentes para mitigar o *context rot*. Adicionalmente, exige-se que cada tarefa traga seus próprios critérios de aceite individuais e restrições de escopo que evitem resoluções precoces do problema principal. A relação operacional de transformação é formalizada na expressão (2):

Pergunta do usuário + Template A.2

→ *Resultado Fase A.2* (2)

Na formulação descrita, “Pergunta do usuário” corresponde ao enunciado principal que orienta a resolução, “Template A.2” identifica o prompt estruturado que instrui o modelo a realizar a divisão em tarefas, e “Resultado Fase A.2” é o cronograma resultante contendo a lista ordenada de tarefas e as condições de aceitação individuais de cada uma delas. O Resultado Fase A.2 gerado é armazenado localmente para posterior coordenação na fase de Execução em Loop.

Exemplo

Considerando o *input* de referência, o modelo deveria retornar uma decomposição como a seguinte.

Saída esperada do modelo:

Tarefa 1

- Tarefa: “Dadas as opções (2, 4, 6), identifique quais desses números são primos.”
- Critérios de aceite:
 - “Deve retornar a lista de números primos encontrados nas alternativas.”
 - “Deve incluir uma breve explicação da regra de identificação de números primos.”
 - “A resposta não deve tentar resolver a questão final.”
 - “A resposta não deve avaliar nenhuma outra condição.”

Tarefa 2

- Tarefa: “Dadas as opções (2, 4, 6), identifique quais desses números são pares.”
- Critérios de aceite:
 - “Deve retornar a lista de números pares encontrados nas alternativas.”
 - “Deve incluir uma breve explicação da regra de identificação de números pares.”

- “A resposta não deve tentar resolver a questão final.”
- “A resposta não deve avaliar nenhuma outra condição.”

Tarefa 3

- Tarefa: “Dadas as opções (2, 4, 6), identifique quais desses números são estritamente maiores que 2.”
- Critérios de aceite:
 - “Deve retornar a lista de números maiores que 2 encontrados nas alternativas.”
 - “Deve incluir uma breve justificativa matemática para a comparação estabelecida.”
 - “A resposta não deve tentar resolver a questão final.”
 - “A resposta não deve avaliar nenhuma outra condição.”

B. Execução em Loop

A fase de execução preserva a estrutura iterativa do paradigma original, mas adapta o mecanismo de conclusão de cada unidade de trabalho. Na formulação original, a conclusão de uma história de usuário é verificada por meio da execução de testes automatizados e da análise dos critérios de aceite associados ao código produzido. No fluxo adaptado, como não há código a ser testado, o modelo simplesmente resolve a tarefa selecionada e, em seguida, verifica se o resultado satisfaz os critérios de aceite individuais definidos no planejamento. Caso os critérios não sejam atingidos, o modelo repete a resolução da mesma tarefa até que sejam satisfeitos.

Ao concluir uma tarefa com sucesso, o modelo realiza dois registros distintos com finalidades diferentes: (i) persiste a resposta aprovada em armazenamento local ou na memória da aplicação, em formato suficientemente estruturado para que cada resultado possa ser recuperado individualmente, servindo de insumo para a fase de Criação da Resposta Final; e (ii) extrai os aprendizados pontuais da execução, isto é, informações objetivas descobertas ao longo das tentativas, que serão injetados no contexto da próxima tarefa como mecanismo de *Fresh Context*. É fundamental ressaltar que esses dois registros têm escopos completamente distintos: os resultados armazenados alimentam exclusivamente a fase de Criação da Resposta Final; os aprendizados pontuais têm papel restrito à Execução em Loop e não participam da construção da resposta final. Antes de iniciar a execução da tarefa seguinte, o contexto é reinicializado e os aprendizados acumulados são injetados como primeira entrada do novo contexto, de forma estruturada e explícita. Esse mecanismo garante que o conhecimento relevante seja preservado sem que o ruído e as redundâncias das etapas anteriores sejam herdadas, mitigando ativamente o fenômeno de *context rot* [7].

Após cada tarefa concluída, o fluxo verifica programaticamente se ainda existem tarefas disponíveis na lista

produzida pelo planejamento. Caso haja, uma nova iteração é iniciada: o contexto é reinicializado, os aprendizados acumulados são injetados e a próxima tarefa é selecionada. Caso contrário, o fluxo avança para a fase de Criação da Resposta Final, levando consigo apenas os resultados armazenados, sem os aprendizados pontuais. Essa verificação é puramente programática e não envolve chamada ao LLM.

B.1 Seleção da tarefa e resolução

Essa subseção corresponde às etapas B.1 e B.2 do fluxo ilustrado na Figura 2: a seleção da próxima tarefa disponível na lista gerada pelo planejamento (B.1) e sua subsequente resolução pelo modelo (B.2). Ao iniciar uma nova tarefa, e somente nesse momento, o contexto é reinicializado. Os aprendizados pontuais acumulados nas tarefas anteriores são injetados no início do novo contexto, antes da descrição da tarefa atual, garantindo continuidade do conhecimento relevante sem carregar o ruído das execuções anteriores. Na primeira tarefa do ciclo, não há aprendizados acumulados, de modo que o contexto inicial contém apenas a tarefa a ser resolvida.

Para processar esta etapa, a descrição da tarefa selecionada é enviada ao modelo em conjunto com o Template B.1 e, caso existam iterações anteriores concluídas, com a memória de aprendizados acumulados. O Template B.1 impõe um limite estrito ao modelo, instruindo-o a focar unicamente no escopo demarcado para a tarefa e a abster-se de resolver a questão final prematuramente. O fluxo lógico de processamento de entradas e geração de respostas preliminares é modelado na expressão (3):

Aprendizados Acumulados

$$+ \text{Tarefa Selecionada} + \text{Template B.1} \\ \longrightarrow \text{Resultado Preliminar B} \quad (3)$$

Nessa relação operacional, “Aprendizados Acumulados” refere-se ao conjunto de anotações internas compactas sintetizadas nas iterações anteriores (que se inicia vazio), “Tarefa Selecionada” consiste no bloco descritivo e critérios individuais definidos em Resultado Fase A.2, e “Template B.1” é o prompt estruturado de instrução. A variável “Resultado Preliminar B” denota a resposta preliminar produzida que será submetida à validação. O Resultado Preliminar B gerado por esta operação é subsequentemente direcionado à fase de controle de qualidade para validação individual dos critérios.

Exemplo

Considerando a Tarefa 1 como primeira tarefa do ciclo, o contexto não contém aprendizados acumulados.

Saída esperada do modelo:

“Entre as alternativas (2, 4, 6), somente o número 2 é primo. Um número primo é aquele divisível exclusivamente por 1 e por ele mesmo. O número 4 possui divisores adicionais (1, 2 e 4) e o 6 também (1, 2,

3 e 6), portanto nenhum dos dois é primo.
Resultado: [2].”

B.2 Verificação dos critérios de aceitação da tarefa

Essa etapa verifica se o Resultado Preliminar B produzido na etapa anterior atende a todos os critérios de aceite individuais associados à tarefa em execução. Trata-se de um mecanismo de controle de qualidade interno: se todos os critérios forem atendidos, o fluxo avança para o armazenamento do resultado; caso contrário, a tarefa é rerepresentada ao modelo para uma nova tentativa. É importante destacar que, ao contrário do que ocorre na transição entre tarefas distintas, o contexto *não* é reinicializado durante as tentativas de repetição de uma mesma tarefa. Essa escolha é intencional e também é usada no *Ralph Loop* original: a tentativa anterior, com os critérios não satisfeitos explicitamente sinalizados, permanece no contexto e auxilia o modelo a identificar o que deve ser corrigido na próxima execução.

Esta validação lógica é formalizada na expressão (4), onde se cruzam os resultados da inferência com os critérios estabelecidos:

Resultado Preliminar B

$$+ \text{Critérios da Tarefa} + \text{Template B.2} \\ \longrightarrow \text{Decisão (Aprovado / Reprovado)} \quad (4)$$

Nesta expressão, “Resultado Preliminar B” é a resposta candidata produzida pelo modelo, “Critérios da Tarefa” corresponde às condições específicas indexadas no Resultado Fase A.2, e “Template B.2” é o prompt estruturado de validação que define as regras do processo de qualidade, culminando na “Decisão (Aprovado / Reprovado)”. Esta etapa de validação operacionaliza-se por meio do Template B.2, o **Cenário de reprovação e nova tentativa**.

Exemplo

Considere a Tarefa 2 (“identifique quais números são pares”). O aprendizado acumulado da Tarefa 1 já está no contexto: “O único número primo entre as alternativas é o 2”. Suponha que o modelo produza na primeira tentativa:

Saída esperada do modelo:

“Todos os números 2, 4 e 6 são pares, pois são divisíveis por 2. No entanto, como apenas o 2 é primo (identificado anteriormente) e o 2 não é maior que 2, nenhuma alternativa satisfaz simultaneamente as três condições. Portanto, a resposta é D) Nenhuma das anteriores.”

Avaliando esse resultado contra os critérios da Tarefa 2:

Saída esperada do modelo:

- “Deve retornar a lista de números pares.”

Atendido: os três números foram identificados.

- “Deve incluir explicação da regra de identificação de pares.”

Atendido: a divisibilidade por 2 foi mencionada.

- “A resposta não deve tentar resolver a questão final.”

Não atendido: o modelo antecipou a resposta final.

- “A resposta não deve avaliar nenhuma outra condição.”

Não atendido: o modelo cruzou condições de outras tarefas.

Decisão: **Reprovado.**

O fluxo retorna à resolução da Tarefa 2, mantendo o contexto com a tentativa reprovada e os critérios não satisfeitos identificados. Na segunda tentativa, com o *feedback* anterior no contexto, o modelo retorna:

Saída esperada do modelo:

“Entre as alternativas (2, 4, 6), todos os três números são pares, pois cada um deles é divisível por 2 sem deixar resto ($2 \div 2 = 1$, $4 \div 2 = 2$, $6 \div 2 = 3$). Resultado: [2, 4, 6].”

Todos os critérios da Tarefa 2 são agora atendidos. Decisão: **Aprovado.** O fluxo avança.

B.3 Armazenamento do resultado

Quando a resposta de uma tarefa é aprovada na verificação dos critérios de aceite, ela é persistida localmente. Somente essa resposta aprovada é armazenada: todo o ruído gerado pelos ciclos de tentativa anteriores (incluindo respostas reprovadas, histórico de verificações e *feedback* intermediário) é descartado na reinicialização do contexto. O armazenamento é indexado por tarefa, de modo que cada resultado possa ser recuperado individualmente como insumo exclusivo da fase de Criação da Resposta Final. A persistência é meramente operacional e não envolve novas chamadas ao modelo, sendo formalizada na expressão (5):

Resposta Aprovada $\rightarrow$ *Armazenamento local* (5)

Nesta expressão, “Resposta Aprovada” representa a solução da tarefa que atendeu satisfatoriamente a todos os critérios na etapa anterior, a qual é direcionada para o “Armazenamento local”, que consiste na persistência física (em disco ou memória) indexada pelo identificador da tarefa correspondente.

Exemplo

A Tarefa 2 exigiu duas tentativas antes de ser aprovada. Somente a segunda é armazenada. A primeira tentativa

reprovada, aquela que antecipou indevidamente a resposta final, permanece apenas no contexto ativo durante o ciclo de repetição e é descartada na reinicialização. Ao término da Execução em Loop, o armazenamento contém exclusivamente as respostas aprovadas de cada tarefa:

- Tarefa 1: “Entre as alternativas (2, 4, 6), somente o número 2 é primo. Um número primo é aquele divisível exclusivamente por 1 e por ele mesmo. O número 4 possui divisores adicionais (1, 2 e 4) e o 6 também (1, 2, 3 e 6), portanto nenhum dos dois é primo. Resultado: [2].”
- Tarefa 2: “Entre as alternativas (2, 4, 6), todos os três números são pares, pois cada um deles é divisível por 2 sem deixar resto ($2 \div 2 = 1$, $4 \div 2 = 2$, $6 \div 2 = 3$). Resultado: [2, 4, 6].”
- Tarefa 3: “Os números estritamente maiores que 2 entre as alternativas são 4 e 6. O número 2 não satisfaz essa condição pois $2 > 2$ é falso. Resultado: [4, 6].”

Esse conjunto é entregue à fase de Criação da Resposta Final como base exclusiva para a construção da resposta.

B.4 Armazenamento dos aprendizados pontuais

Os aprendizados pontuais funcionam como as “anotações internas” do fluxo de *thinking*: são fatos secos e objetivos descobertos durante a execução de uma tarefa que podem ser úteis para guiar as tarefas subsequentes. Esses aprendizados não devem ser conceitos redundantes ou óbvios, mas sim dados de controle, metadados operacionais e restrições práticas descobertas na execução, como, por exemplo, registrar uma versão da linguagem específica disponível no ambiente. A extração de aprendizados considera o contexto completo da tarefa, incluindo as tentativas reprovadas, pois fatos úteis podem ter emergido mesmo em execuções que não passaram na verificação de critérios. Os aprendizados pontuais têm escopo estritamente restrito à Execução em Loop: são injetados no início do contexto de cada nova tarefa para subsidiar a resolução, mas não são incluídos, em nenhuma hipótese, na fase de Criação da Resposta Final.

A extração de conhecimento é estruturada ao aplicar o Template B.4 sobre o histórico completo de execução da tarefa. A instrução exige que o modelo compile exclusivamente fatos concretos descobertos durante as tentativas (aprovadas ou não), registrando-os em formato de tópicos sucintos e secos, sem justificativas ou descrições narrativas de processo. A geração dessas anotações internas é representada na expressão (6):

Contexto Completo da Tarefa + *Template B.4*

$\rightarrow$ *Aprendizados Pontuais* (6)

Nessa expressão, “Contexto Completo da Tarefa” compreende todo o histórico acumulado no contexto (incluindo tentativas anteriores reprovadas e interações com o validador), “Template B.4” representa o prompt fixo que rege a compilação puramente factual, e “Aprendizados Pontuais” representa os tópicos secos resultantes anexados à Memória Acumulada. Os aprendizados pontuais resultantes são anexados à Memória Acumulada da aplicação. Diferente dos resultados estruturados de B.3, esses fatos acumulados destinam-se unicamente a guiar os novos contextos das tarefas subsequentes e não alimentam a resposta do usuário.

Exemplo

Após a conclusão da Tarefa 1 (identificação de números primos), a Memória Acumulada conteria um único aprendizado pontual realmente útil para guiar as etapas subsequentes, em vez de uma cópia da resposta completa gerada na etapa anterior ou de definições óbvias:

Saída esperada do modelo:

“Um número primo é aquele que só é divisível por 1 e por ele mesmo.”

Esse bloco compacto de fatos atômicos é injetado no início do contexto das tarefas subsequentes para auxiliá-las, sem carregar a descrição e o formato verbal da resposta completa gerada anteriormente.

Como contraponto, o trecho a seguir ilustra o formato **inválido** de aprendizado, por ser excessivamente verboso, conter contexto processual irrelevante e não focar na restrição operacional útil:

Inválido: “Durante a execução da Tarefa 1, analisamos os números 2, 4 e 6, e depois de validarmos os divisores de cada um deles, concluímos que apenas o 2 é primo pois é divisível apenas por 1 e por ele mesmo.”

O aprendizado pontual válido extrai puramente a informação útil: “Um número primo é aquele que só é divisível por 1 e por ele mesmo.”

A distinção entre resultado armazenado (etapa anterior) e aprendizado pontual é estrutural e intencional. O resultado é a resposta completa e verificada da tarefa, destinada à síntese da fase de Criação da Resposta Final. O aprendizado é um fragmento seco de fato, destinado exclusivamente a subsidiar a execução das tarefas seguintes dentro do loop.

C. Criação da Resposta Final

A terceira fase constitui uma adição exclusiva do fluxo adaptado, sem correspondência direta na formulação original. No *Ralph Wiggum Loop* concebido para engenharia de software, o produto final é o próprio código implementado e versionado ao longo das histórias; não há, portanto, necessidade de uma etapa de síntese do conteúdo e geração de resposta. No fluxo adaptado, os resultados das tarefas

individuais são fragmentos de raciocínio que precisam ser compilados em uma resposta coesa e completa.

Após o encerramento do loop, o modelo compila os resultados armazenados e verifica se as informações produzidas são suficientes para satisfazer todos os critérios de aceite gerais definidos no planejamento. Se os critérios forem integralmente atendidos, o modelo constrói a resposta final e a retorna ao usuário. Caso contrário, o sistema infere que o planejamento inicial foi insuficiente para cobrir todos os aspectos da pergunta e inicia uma fase de Planejamento Adicional: o modelo identifica os critérios ainda não atendidos, cria novas tarefas individuais para supri-los e retorna à fase de Execução em Loop. Esse mecanismo garante que lacunas de planejamento sejam identificadas e corrigidas antes que a resposta final seja construída, preservando a completude e a coerência da saída.

C.1 Compilação dos resultados e verificação dos critérios gerais

Essa etapa reúne todos os resultados armazenados durante a Execução em Loop e verifica se o conjunto de informações produzido é suficiente para satisfazer cada um dos critérios de aceite gerais definidos na etapa A.1. A distinção central em relação à verificação realizada na fase de Execução em Loop reside no escopo da avaliação: na etapa anterior, a verificação possui caráter local, avaliando cada tarefa individualmente frente aos seus próprios critérios; nesta etapa, por outro lado, a avaliação é global, considerando se a união dos dados acumulados atende plenamente ao enunciado geral.

A validação global é efetuada ao associar os resultados consolidados com os critérios de A.1 sob as diretrizes do Template C.1. O modelo avalia individualmente as condições e emite um veredito estruturado (aprovado ou reprovado), apontando as eventuais pendências. A dinâmica de controle global é formalizada na expressão (7):

Resultados Armazenados

+ Critérios Gerais (A.1) + Template C.1

→ Decisão (Aprovado / Reprovado) (7)

Nesta formulação global, “Resultados Armazenados” refere-se ao conjunto de respostas das tarefas que foram homologadas individualmente, “Critérios Gerais (A.1)” denota as diretrizes gerais de aceitação mapeadas no Resultado Fase A.1, e “Template C.1” é o prompt estruturado de validação global que orienta o modelo a tomar a “Decisão (Aprovado / Reprovado)”. Em caso de conformidade de todas as diretrizes, o fluxo prossegue diretamente para a consolidação e resposta; caso contrário, é deflagrada a etapa de Planejamento Adicional.

Exemplo

Cenário de aprovação. Com os três resultados disponíveis ao término do loop, a avaliação contra os critérios gerais de A.1 produz:

Saída esperada do modelo:

Resultados disponíveis:

- Tarefa 1: “Entre as alternativas (2, 4, 6), somente o número 2 é primo. Um número primo é aquele divisível exclusivamente por 1 e por ele mesmo. O número 4 possui divisores adicionais (1, 2 e 4) e o 6 também (1, 2, 3 e 6), portanto nenhum dos dois é primo. Resultado: [2].”
- Tarefa 2: “Entre as alternativas (2, 4, 6), todos os três números são pares, pois cada um deles é divisível por 2 sem deixar resto ($2 \div 2 = 1$, $4 \div 2 = 2$, $6 \div 2 = 3$). Resultado: [2, 4, 6].”
- Tarefa 3: “Os números estritamente maiores que 2 entre as alternativas são 4 e 6. O número 2 não satisfaz essa condição pois $2 > 2$ é falso. Resultado: [4, 6].”

Avaliação dos critérios gerais:

- “A pergunta deve ser respondida em Português do Brasil.”
Atendível: todos os resultados estão em português.
- “Responda somente a alternativa, sem explicações adicionais.”
Atendível: os dados disponíveis permitem identificar a alternativa correta.
- “O valor encontrado deve corresponder a uma das alternativas.”
Atendível: primo $\cap$ par $\cap$ maior que 2 = $\emptyset$, o que corresponde à alternativa D.

Decisão: **Aprovado.**

O fluxo avança para a construção da resposta final.

Cenário de reprovação. Considere uma variação em que os critérios gerais incluam: “A resposta deve ser sustentada por uma verificação explícita de qual conjunto de alternativas satisfaz simultaneamente todas as condições enunciadas.” Os três resultados cobrem cada condição individualmente, mas nenhuma tarefa realizou a análise de interseção.

Saída esperada do modelo:

- “Verificação explícita da interseção dos conjuntos.”
Não atendido: nenhuma tarefa realizou a verificação combinada das três condições.

Decisão: **Reprovado.**

O fluxo avança para o Planejamento Adicional.

C.2 Planejamento Adicional

Quando os critérios gerais não são atendidos, o Planejamento Adicional funciona como uma extensão da fase A.2: identifica as lacunas específicas nos resultados disponíveis e cria novas tarefas individuais para supri-las. Diferentemente do planejamento inicial, que parte da pergunta do usuário sem qualquer contexto de execução, o Planejamento Adicional tem acesso ao conjunto de resultados já produzidos e ao mapeamento preciso dos critérios que ainda não foram satisfeitos. Essa informação torna as novas tarefas mais pontuais e direcionadas, evitando retrabalho sobre o que já foi verificado. As novas tarefas são adicionadas à fila de execução e o fluxo retorna à etapa B.1, agora com o contexto dos aprendizados acumulados de todas as tarefas anteriores disponível.

O planejamento adicional atua de forma cirúrgica para suprir as lacunas apontadas pela verificação global. Ao conjugar os critérios não satisfeitos e as saídas previamente geradas com o Template C.2, o modelo é induzido a planejar novos subproblemas independentes capazes de complementar o conteúdo em falta. Esse processo de expansão do escopo é delineado na expressão (8):

Critérios Não Atendidos

+ Resultados Armazenados + Template C.2

→ *Novas Tarefas* (8)

Nesta expressão, “Critérios Não Atendidos” são os critérios gerais identificados como não satisfeitos na etapa anterior, “Resultados Armazenados” são as respostas aprovadas de todas as tarefas já concluídas, e “Template C.2” é o prompt fixo de instrução descrito acima que direciona o modelo a produzir as “Novas Tarefas”. As novas tarefas, estruturadas com critérios individuais de aceite próprios, são inseridas no topo da fila e processadas no ciclo de Execução em Loop, garantindo que o planejamento convirja para o aceite global.

Exemplo

A partir da reprovação identificada no cenário anterior, o modelo produziria novas tarefas como a seguinte.

Saída esperada do modelo:

Tarefa 4

- Tarefa: “Dadas as listas já identificadas — primos: [2]; pares: [2, 4, 6]; maiores que 2: [4, 6] —, determine quais números aparecem simultaneamente nas três listas.”
- Critérios de aceite:
 - “Deve retornar o resultado da interseção das três listas, podendo ser um conjunto vazio.”
 - “Deve apresentar justificativa explicitando a presença ou ausência de cada candidato em cada lista.”

– “A resposta não deve construir a resposta final ao usuário.”

Essa nova tarefa é enviada à Execução em Loop. Com os aprendizados de T1, T2 e T3 injetados no contexto, o modelo executa a Tarefa 4.

Saída esperada do modelo:

“Verificando a interseção: primos $[2] \cap$ pares $[2, 4, 6] \cap$ maiores que 2 $[4, 6]$. O número 2 está em {primos} e {pares}, mas não em {maiores que 2} (pois $2 > 2$ é falso). Os números 4 e 6 estão em {pares} e {maiores que 2}, mas não em {primos}. Resultado da interseção: {} (conjunto vazio — nenhum número satisfaz simultaneamente as três condições).”

Após a aprovação da Tarefa 4, o fluxo retorna à compilação dos resultados para nova verificação. Desta vez, com quatro resultados disponíveis, todos os critérios gerais são atendidos e o fluxo avança para a construção da resposta final.

O mecanismo de Planejamento Adicional pode ocorrer mais de uma vez caso as novas tarefas criadas ainda não sejam suficientes para satisfazer todos os critérios gerais. A cada retorno à compilação, o conjunto de resultados disponíveis é maior, convergindo progressivamente para a completude.

C.3 Construção da resposta final

Com todos os critérios gerais satisfeitos, o modelo compõe a resposta final ao usuário. Essa etapa não realiza um novo raciocínio analítico sobre o problema: seu objetivo é exclusivamente organizar e apresentar os resultados já produzidos no formato e idioma definidos pelos critérios gerais (Resultado Fase A.1). A distinção entre esta etapa e as anteriores é deliberada: ao separar o raciocínio analítico, realizado de forma incremental e verificada durante a Execução em Loop, da síntese da resposta final, reduz-se o risco de que a fase de apresentação introduza inferências não verificadas ou contradiga os resultados produzidos.

A síntese final é operacionalizada ao mesclar os resultados consolidados e os critérios gerais com as diretrizes do Template C.3, que proíbe terminantemente a inserção de novos fatos ou especulações que não estejam fundamentados na base de conhecimento gerada pelas tarefas. A relação operacional é expressa na expressão (9):

Resultados Compilados

$$+ \text{Critérios Gerais (A.1)} + \text{Template C.3} \\ \longrightarrow \text{Resposta Final} \quad (9)$$

Nessa expressão, “Resultados Compilados” são as respostas aprovadas de todas as tarefas resolvidas e acumuladas, “Critérios Gerais (A.1)” são os critérios gerais definidos

no Resultado Fase A.1, e “Template C.3” é o prompt fixo de instrução que orienta a compilação e formatação para produzir a “Resposta Final”. Esta resposta compilada é finalmente entregue ao usuário, concluindo todo o ciclo do harness de IA.

Exemplo

Em ambos os cenários (aprovação direta com três tarefas ou com Planejamento Adicional em quatro tarefas), os resultados indicam que $\text{primo} \cap \text{par} \cap \text{maior que 2} = \emptyset$. Respeitando os critérios gerais, a resposta final produzida é:

Saída esperada do modelo:

D) Nenhuma das anteriores

Essa resposta é então retornada ao usuário, encerrando o fluxo.

IV. Metodologia de avaliação

A metodologia de avaliação visa mensurar o impacto do harness proposto na acurácia de modelos de linguagem em tarefas de raciocínio geral, comparando sistematicamente a inferência direta com a inferência orquestrada. Para essa validação, os experimentos são conduzidos com três modelos da família Llama 3.1, nas variantes de 8B, 70B e 405B parâmetros, escolhidos por representarem uma progressão controlada de escala computacional dentro de uma mesma arquitetura base. Essa escolha permite isolar o efeito da orquestração do efeito da escala, avaliando se os ganhos introduzidos pelo harness se manifestam de forma consistente independentemente do tamanho do modelo.

Para cada variante, são comparadas duas configurações de inferência: (i) uma chamada direta ao modelo, na qual toda a resposta é produzida em uma única etapa de inferência sem qualquer processamento auxiliar; e (ii) a mesma inferência mediada pelo harness proposto, que aplica o fluxo completo de Planejamento, Execução em Loop e Criação da Resposta Final descrito na seção de metodologia, sem o uso de ferramentas externas. O desempenho é mensurado por meio de questões amostradas das bases MMLU [6] e GPQA [15], escolhidas por seu elevado rigor acadêmico e por serem amplamente adotadas como referência na literatura de avaliação de LLMs. A métrica principal é a acurácia, obtida pela correspondência estrita entre a alternativa selecionada pelo sistema e o gabarito oficial.

Para contextualizar os resultados obtidos em relação ao estado da arte, os valores de acurácia dos modelos Llama 3.1 nas duas configurações são comparados com os resultados de inferência direta já publicados para Claude Sonnet 4.6 e GPT 5.4 nos mesmos datasets. Esses modelos comerciais não são submetidos ao harness proposto: sua função é exclusivamente estabelecer um ponto de referência de mercado que permita situar o desempenho alcançado pela abordagem proposta em relação a sistemas modernos de grande escala.

Tabela I. Cronograma das atividades do projeto.

Atividade	fev	mar	abr	mai	jun	jul	ago	set	out	nov
Revisão bibliográfica e refinamento da proposta	X	X	X	X						
Definição da arquitetura		X	X	X	X					
Desenvolvimento do Paper		X	X	X	X	X	X	X	X	X
Implementação prática do código				X	X	X	X	X	X	
Análise final									X	X

Referências

- [1] Anthropic, *Claude Code*, <https://www.anthropic.com/claude-code>, 2026.
- [2] T. B. Brown et al., “Language Models are Few-Shot Learners,” em *Advances in Neural Information Processing Systems*, 2020.
- [3] M. Chen et al., “Evaluating Large Language Models Trained on Code,” *arXiv preprint arXiv:2107.03374*, 2021.
- [4] X. Chen, M. Lin, N. Schärli e D. Zhou, “Teaching Large Language Models to Self-Debug,” *arXiv preprint arXiv:2304.05128*, 2023.
- [5] G. Ghuntley, *Ralph Loop: A Structured Orchestration Pattern for LLM Inference*, Online. Disponível em: <https://ghuntley.com/specs/ralph/>, Acesso em: abr. 2026, 2025.
- [6] D. Hendrycks et al., “Measuring Massive Multitask Language Understanding,” em *International Conference on Learning Representations*, 2021.
- [7] K. Hong, A. Troynikov e J. Huber, “Context Rot: How Increasing Input Tokens Impacts LLM Performance,” Chroma, rel. técn., jul. de 2025. endereço: <https://trychroma.com/research/context-rot>
- [8] Z. Ji et al., “Survey of hallucination in natural language generation,” *ACM Computing Surveys*, v. 55, n. 12, pp. 1–38, 2023. doi: 10.1145/3571730
- [9] T. Khot et al., “Decomposed prompting: A modular approach for solving complex tasks,” *arXiv preprint arXiv:2210.02406*, 2022.
- [10] Y. Lee, R. Nair, Q. Zhang, K. Lee, O. Khattab e C. Finn, “Meta-Harness: End-to-End Optimization of Model Harnesses,” *arXiv preprint arXiv:2603.28052*, 2026.
- [11] N. F. Liu et al., “Lost in the Middle: How Language Models Use Long Contexts,” *Transactions of the Association for Computational Linguistics*, v. 12, pp. 277–294, 2024.
- [12] A. Madaan et al., “Self-Refine: Iterative Refinement with Self-Feedback,” *arXiv preprint arXiv:2303.17651*, 2023.
- [13] C. McComb et al., “Supervising Ralph Wiggum: Exploring a Metacognitive Co-Regulation Agentic AI Loop for Engineering Design,” *arXiv preprint arXiv:2603.24768*, 2026.
- [14] OpenCLI, <https://opencli.ai/>, 2026.
- [15] D. Rein et al., “GPQA: A Graduate-Level Google-Proof Q&A Benchmark,” *arXiv preprint arXiv:2311.12022*, 2023.
- [16] N. Shinn, F. Cassano, B. Labash, A. Gopinath, K. Narasimhan e S. Yao, “Reflexion: Language Agents with Verbal Reinforcement Learning,” *arXiv preprint arXiv:2303.11366*, 2023.
- [17] A. Vaswani et al., “Attention is All You Need,” em *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [18] L. Wang et al., “Plan-and-solve prompting: Improving zero-shot chain-of-thought reasoning by large language models,” *arXiv preprint arXiv:2305.04091*, 2023.
- [19] Z. Wang et al., “Beyond the Strongest LLM: Multi-Turn Multi-Agent Orchestration vs. Single LLMs on Benchmarks,” *arXiv preprint arXiv:2509.23537*, 2025.
- [20] J. Wei et al., “Chain-of-Thought Prompting Elicits Reasoning in Large Language Models,” *arXiv preprint arXiv:2201.11903*, 2022.
- [21] S. Yao et al., “ReAct: Synergizing Reasoning and Acting in Language Models,” *arXiv preprint arXiv:2210.03629*, 2022.
- [22] S. Yao et al., “Tree of Thoughts: Deliberate Problem Solving with Large Language Models,” *arXiv preprint arXiv:2305.10601*, 2023.
- [23] M. Zaharia et al., *The Shift from Models to Compound AI Systems*, Berkeley Artificial Intelligence Research Blog. Disponível em: <https://bair.berkeley.edu/blog/2024/02/18/compound-ai-systems/>, Acesso em: mai. 2026, 2024.
- [24] W. X. Zhao et al., “A Survey of Large Language Models,” *arXiv preprint arXiv:2303.18223*, 2023.
- [25] D. Zhou et al., “Least-to-most prompting enables complex reasoning in large language models,” *arXiv preprint arXiv:2205.10625*, 2022.