

Um Harness de IA para Resolução de Perguntas em Linguagem Natural: Adaptando o Ralph Wiggum Loop Além do Desenvolvimento de Software

Hugo Emílio Nomura, Pedro Henrique Correia de Oliveira, Pedro Henrique Satoru Lima Takahashi, Vitor Monteiro Vianna

Ciência da Computação – Centro Universitário FEI, campus São Paulo

unifhnomura@fei.edu.br, unifpoliveira@fei.edu.br, unifptakahashi@fei.edu.br, unievvianna@fei.edu.br

Orientador: Charles Henrique Porto Ferreira

Departamento de Ciência da Computação, Centro Universitário FEI

cferreira@fei.edu.br

Resumo: Os *Large Language Models* (LLMs), embora sejam em essência geradores probabilísticos de *tokens*, alcançam ganhos expressivos de desempenho quando o processo de inferência é estruturado por *harnesses* que incorporam planejamento, decomposição de tarefas e ciclos iterativos de refinamento. Entretanto, arquiteturas que preservam o histórico completo de execução em uma única janela de contexto introduzem degradação progressiva da qualidade das respostas conforme o contexto cresce, fenômeno denominado *context rot*, que compromete a confiabilidade dos resultados em execuções longas.

Este trabalho propõe a adaptação do *Ralph Wiggum Loop*, paradigma de orquestração originalmente concebido para fluxos focados em desenvolvimento e engenharia de software e que traz soluções para mitigar problemas de *context rot*, para um fluxo de resolução generalista, focado em responder perguntas em linguagem natural. A hipótese é que essa estrutura melhora a qualidade das respostas em relação à inferência singular, e essa hipótese é avaliada por meio dos *benchmarks* MMLU e GPQA, comparando chamadas diretas ao modelo com execuções mediadas pelo *harness* proposto, utilizando modelos da família Llama 3.1 com diferentes quantidades de parâmetros. A acurácia, medida pela correspondência entre a alternativa selecionada pelo sistema e o gabarito oficial, é adotada como métrica principal.

Palavras-chaves: *Large Language Models* (LLMs). Ralph Wiggum Loop. Sistemas Compostos de IA. Engenharia de Prompt. Decaimento de Contexto (*context rot*).

I. Introdução

Os *Large Language Models* (LLMs) consolidaram-se como o núcleo de uma nova geração de sistemas capazes de executar tarefas complexas de processamento de linguagem natural, incluindo geração de texto, resolução de problemas, planejamento intermediário e suporte à tomada de decisão. Apesar dessas capacidades, os modelos que servem como base para esses sistemas continuam sendo, em essência, geradores probabilísticos de *tokens*, operando a partir de uma entrada de texto e retornando como saída outro texto. Nesse contexto, parte significativa da evolução recente dos sistemas baseados em LLMs passou a ocorrer não apenas nos próprios modelos, mas também nas estruturas responsáveis por organizar sua utilização prática. Trabalhos recentes, como [1], afirmam que “*The performance of large language model (LLM) systems depends not only on model weights, but also on their harness: the code that determines what information to store, retrieve, and present to the model*”, evidenciando o papel dos chamados *harnesses* na ampliação das capacidades desses sistemas. Ferramentas modernas, como o *ChatGPT*, incorporam tais mecanismos para adicionar camadas de coordenação, decomposição de tarefas, validação intermediária e orquestração de múltiplas inferências, permitindo que o modelo execute fluxos significativamente mais sofisticados do que uma única chamada linear de entrada e saída.

Abordagens baseadas em uma única chamada ao modelo, nas quais toda a resposta é produzida em uma única etapa de inferência, apresentam limitações importantes em tarefas que exigem raciocínio complexo, múltiplas etapas de decisão ou validações intermediárias. Como resposta a esse problema, diferentes linhas de pesquisa passaram a explorar fluxos estruturados de *thinking*, nos quais o processo de inferência é explicitamente decomposto em etapas sucessivas de raciocínio, planejamento, execução e refinamento. Trabalhos baseados em *Chain-of-Thought* [2], *Tree of Thoughts* [3] e na técnica de *Least-to-Most* [4] demonstram que a decomposição explícita do raciocínio favorece significativamente a resolução de tarefas complexas. De maneira semelhante, abordagens como *ReAct* [5] combinam raciocínio e ações iterativas, enquanto métodos como *Reflexion* [6], *Self-Debugging* [7] e *Self-Refine* [8] exploram ciclos sucessivos de avaliação, crítica e refinamento da própria resposta gerada. Em conjunto, esses trabalhos indicam que ganhos de desempenho não dependem exclusivamente do tamanho do modelo ou da quantidade de *tokens* gerados, mas também da maneira como o processo de inferência é estruturado, coordenado e validado ao longo da execução.

Apesar dos ganhos observados nessas arquiteturas iterativas compostas por agentes, ciclos de reflexão ou *pipelines* sucessivos, tais abordagens também introduzem novos desafios relacionados ao gerenciamento do contexto

acumulado durante a inferência. Em muitos desses sistemas, o histórico completo de interações permanece armazenado na janela de contexto ao longo de toda a execução como mecanismo de preservação da continuidade do raciocínio. Embora essa estratégia favoreça rastreabilidade e coerência entre etapas intermediárias, ela também aumenta progressivamente a dificuldade de recuperação de informações relevantes conforme o contexto cresce. Liu et al. [9], por exemplo, demonstram que ocorre perda de desempenho em tarefas que exigem localizar informações relevantes em sequências extensas. Trabalhos recentes também passaram a discutir fenômenos associados à degradação progressiva do contexto em execuções longas, incluindo compressão implícita de informações, perda de relevância contextual e aumento de inconsistências ao longo da inferência. Esses efeitos vêm sendo frequentemente associados, ao conceito de *context rot*, termo utilizado por Hong et al. [10] para descrever a degradação gradual da qualidade das respostas conforme o volume de contexto acumulado aumenta.

Além do avanço acadêmico dessas abordagens, a indústria de engenharia de software também passou a investir intensamente em arquiteturas de *deep thinking* e em *harnesses* especializados para ampliar a capacidade operacional de LLMs em tarefas complexas de desenvolvimento. Ferramentas recentes, como *Claude Code*, *GPT Codex*, *OpenCLI* e *Devin*, exemplificam essa tendência ao combinar planejamento, decomposição de tarefas, validação iterativa e execução coordenada de múltiplas inferências. Nesse contexto, uma das abordagens que ganhou notoriedade foi o *Ralph Wiggum Loop* [11], popularizado por Geoffrey Huntley no contexto de engenharia de software. Em sua formulação original, entretanto, o modelo não foi concebido para cenários generalistas, mas especificamente para fluxos de desenvolvimento baseados em conceitos próprios da engenharia de software, como definição de funcionalidades, requisitos, critérios de aceite e integração com sistemas de versionamento, como o *Git*. Ainda assim, sua estrutura apresenta dois princípios centrais relevantes para os problemas discutidos na literatura de LLMs: a decomposição do processo em tarefas independentes, reduzindo a necessidade de reaproveitamento contínuo do contexto entre etapas, e a execução iterativa de cada tarefa até que critérios mínimos de qualidade sejam satisfatoriamente atingidos.

Este trabalho parte de três premissas consolidadas na literatura: que abordagens de *thinking* podem melhorar a qualidade das respostas de LLMs em cenários específicos, como os de tarefas complexas; que tais abordagens introduzem problemas associados ao crescimento excessivo do contexto acumulado, fenômeno descrito como *context rot*; e que o *Ralph Wiggum Loop* [11], concebido por Huntley para fluxos de engenharia de software, oferece princípios estruturais capazes de mitigar o problema de *context rot* por meio de decomposição de tarefas e isolamento contextual entre etapas. A partir dessas premissas, propõe-se a adaptação do *Ralph Wiggum Loop* para um contexto generalista de resolução de tarefas em linguagem natural a partir de um *prompt* de entrada fornecido pelo usuário. Diferentemente da proposta original, centrada em desenvolvimento

de software, definições de funcionalidades, critérios de aceite baseados em requisitos funcionais e integração com ferramentas de versionamento (como *Git*), a adaptação proposta investiga se, ao adaptar a estrutura do *Ralph Wiggum Loop* a um fluxo completo de *thinking* aplicável à resolução de perguntas gerais e à exploração de problemas diversos e de diferentes complexidades, também haverá melhora na qualidade dessas respostas quando comparadas a uma única etapa de inferência.

Para avaliar essa hipótese de maneira objetiva, reproduzível e quantitativa, o trabalho compara diretamente duas estratégias de inferência: (i) uma chamada tradicional a um modelo de LLM, na qual toda a resposta é produzida em uma única etapa de inferência; e (ii) uma execução mediada pelo *harness* proposto, que adapta o *Ralph Wiggum Loop* para cenários generalistas. O objetivo experimental é medir em que magnitude a aplicação desse fluxo estruturado de *thinking* melhora a qualidade das respostas em relação à inferência singular tradicional. Para permitir essa quantificação, os experimentos utilizam *benchmarks* compostos por questões e respostas previamente definidas, estratégia amplamente adotada para mensuração de ganhos em arquiteturas de raciocínio e orquestração de LLMs, e usada em trabalhos como *ReAct* [5] e *Beyond the Strongest LLM* [12]. Os experimentos são conduzidos com diferentes modelos da família Llama 3.1, com diferentes quantidades de parâmetros utilizados na execução do modelo, representando distintos níveis de complexidade computacional, e avaliados por meio dos *benchmarks* MMLU [13] e GPQA [14], sendo a acurácia, medida pela quantidade de acertos entre a alternativa selecionada pelo sistema de LLM e o gabarito oficial.

II. Referencial Bibliografico

Esta seção apresenta os conceitos fundamentais necessários para a compreensão do trabalho proposto. São definidos os termos técnicos centrais utilizados ao longo do texto, descritas as principais estratégias de raciocínio e refinamento aplicadas a modelos de linguagem, e introduzido o paradigma de orquestração adotado neste trabalho.

A. Modelos de Linguagem e a Arquitetura de Harness

Embora os *Large Language Models* (LLMs) [15] sejam amplamente consolidados como geradores probabilísticos de *tokens* baseados na arquitetura *Transformer* [16], a evolução recente na aplicação dessas tecnologias migrou de chamadas diretas e lineares para o uso de estruturas de orquestração mais robustas. Um detalhamento teórico e histórico aprofundado sobre o funcionamento desses modelos de linguagem pode ser encontrado no levantamento conduzido por Zhao et al. [17].

Na prática, a organização dessas interações é viabilizada por meio de um *harness*, termo que se refere à estrutura lógica e às regras de orquestração que envolvem um modelo de linguagem para guiar seu processo de inferência, funcionando como uma camada de coordenação entre o *prompt* inicial do usuário e a saída do modelo [12], [18]. Um *harness* pode incluir etapas de planejamento, decompo-

sição de tarefas, validação intermediária e composição de respostas finais. Variações na arquitetura do *harness* podem causar impactos significativos no desempenho do sistema como um todo, mesmo quando o modelo base permanece o mesmo.

Esse conceito está diretamente relacionado à noção de *Sistemas Compostos de IA*, definida por Zaharia et al. [18] como arquiteturas que resolvem tarefas de inteligência artificial por meio de múltiplos componentes que interagem entre si, incluindo chamadas a modelos, recuperadores de informação e ferramentas externas. Segundo essa perspectiva, os ganhos mais significativos em aplicações de IA contemporâneas passaram a depender da engenharia de sistemas que combinam componentes especializados em fluxos coordenados, em vez de se apoiarem unicamente no aumento de escala dos modelos base [18].

Essa tendência se manifesta em ferramentas industriais que utilizam LLMs integrados a *harnesses* especializados para tarefas de engenharia e automação. Exemplos incluem o Claude Code [19], interface de linha de comando voltada ao desenvolvimento assistido por IA; o GPT Codex [20], otimizado para geração e compreensão de código; e o OpenCLI [21], voltado à automação de comandos de terminal. Essas ferramentas demonstram como a combinação de planejamento, decomposição de tarefas e validação iterativa expande a capacidade computacional útil dos modelos base.

B. Estratégias de Raciocínio e Refinamento

A literatura demonstra que a qualidade da inferência de um LLM pode ser melhorada de forma significativa quando o processo é estruturado em fases [2], [3]. O método *Chain-of-Thought* [2] e sua generalização *Tree of Thoughts* [3] mostraram a importância de induzir o modelo a explicitar passos intermediários de raciocínio. Abordagens como *ReAct* [5] ampliaram esse princípio ao combinar o raciocínio interno do modelo com a capacidade de invocar ferramentas externas, permitindo corrigir alucinações por meio de observações diretas do ambiente.

De forma complementar, pipelines baseados em ciclos de *feedback* iterativo também apresentam ganhos consistentes. O framework *Reflexion* [6] introduziu ciclos nos quais o modelo atua como seu próprio crítico, revisando saídas com base em reforço verbal externo. A abordagem de *Self-Debugging* [7] demonstrou que LLMs podem identificar e corrigir seus próprios erros quando guiados de forma sistemática. Na mesma direção, o método *Self-Refine* [8] consolidou a eficácia do refinamento iterativo ao demonstrar que modelos podem gerar *feedback* crítico sobre suas próprias respostas e utilizá-lo para melhorar as saídas de forma sucessiva, contornando limitações da geração em uma única etapa. Essa capacidade de autocritica e revisão contínua constitui uma premissa fundamental para a proposta deste trabalho.

Além dessas abordagens, métodos focados na decomposição de tarefas complexas também contribuem para a redução de erros lógicos e omissões. Técnicas de *prompting* baseadas em decomposição, como *Least-to-Most* [4], *Decomposed Prompting* [22] e *Plan-and-Solve* [23], sustentam

que separar o planejamento da execução e dividir problemas em subproblemas menores melhora o desempenho do modelo, especialmente quando combinado com mecanismos de validação intermediária.

C. Degradação de Contexto

Embora as técnicas apresentadas nas subseções anteriores tenham demonstrado eficácia individual, muitas delas dependem do acúmulo contínuo de estado em uma única janela de contexto, o que pode agravar problemas de degradação à medida que o histórico cresce. Liu et al. [9] demonstraram empiricamente que LLMs apresentam perda significativa de desempenho quando precisam recuperar informações relevantes posicionadas no meio de sequências longas, fenômeno descrito como “perdidos no meio” (*lost in the middle*).

Na prática, esse comportamento se manifesta de diversas formas: compressão implícita de informações, perda de relevância contextual, aumento de inconsistências e maior incidência de alucinações em execuções prolongadas [9], [17]. A literatura contemporânea frequentemente associa esse conjunto de efeitos ao conceito de *context rot*, referindo-se à degradação progressiva da qualidade das respostas conforme o contexto acumula ruído, redundâncias e informações que competem pela atenção do modelo [9].

D. O Ralph Wiggum Loop

Diante dos problemas de degradação de contexto, o *Ralph Wiggum Loop* [11] surgiu na comunidade de engenharia de software como um paradigma de orquestração que aborda diretamente essa limitação. Idealizado por Geoffrey Huntley, o paradigma parte de um conjunto de requisitos fornecidos como entrada e os decompõe em histórias de usuário, conceito consolidado na disciplina de engenharia de software. Cada história é tratada de forma atômica: o modelo implementa uma solução, executa testes e verifica se os critérios de aceite foram satisfeitos; caso contrário, o ciclo se repete até que a história seja concluída com êxito. Ao término de cada história, seus resultados não são carregados diretamente para a execução seguinte, evitando o acúmulo progressivo de estado que caracteriza arquiteturas tradicionais de agentes.

Um aspecto central dessa abordagem é o princípio de *Fresh Context* [11]: ao iniciar cada nova história, o contexto de execução é completamente reinicializado. Antes de qualquer instrução sobre a nova história, os aprendizados gerais extraídos das histórias anteriores são injetados como primeira entrada nesse novo contexto, de forma estruturada e explícita. Dessa maneira, o paradigma preserva o conhecimento relevante acumulado sem herdar o ruído, as redundâncias e as informações obsoletas que degradam progressivamente a qualidade das respostas em execuções longas, mitigando ativamente o fenômeno de *context rot* [10].

Em sua formulação original, o *Ralph Wiggum Loop* foi concebido especificamente para fluxos de engenharia de software, com etapas voltadas à definição de funcionalidades, requisitos, critérios de aceite e integração com sistemas de versionamento como *Git*. Ainda assim, seus princípios




Figura 1. Ralph Wiggum Loop original.

de execução *stateless* e validação iterativa apresentam relevância direta para os problemas discutidos na literatura de LLMs. A validação acadêmica dessa abordagem foi reforçada pelo estudo de McComb et al. [24], que avaliou o impacto de agentes baseados no *Ralph Wiggum Loop* na resolução de problemas complexos de design de engenharia, confirmando a eficácia do paradigma *stateless* em contextos que exigem raciocínio estruturado e iterativo. Este trabalho se apoia nesses fundamentos para justificar o uso do paradigma, adaptando sua orquestração para a resolução de questões de propósito geral em múltiplos domínios do conhecimento.

III. Metodologia

A adaptação do *Ralph Wiggum Loop* para um contexto generalista de resolução de perguntas em linguagem natural exige ajustes estruturais em relação à formulação original, que foi concebida exclusivamente para fluxos de engenharia de software. A Figura 2 apresenta uma visão geral do fluxo proposto, que preserva os princípios centrais do paradigma original, representado na Figura 1.

Em linhas gerais, propomos uma conversão do conceito de histórias de usuário para tarefas, o que nos permite manter um fluxo muito próximo do original, contendo as etapas de “Planejamento” e “Execução em Loop”. Entretanto, passa a ser necessário considerar a criação de um retorno ao usuário, algo que não constitui uma preocupação no *Ralph Wiggum Loop* original. Dessa forma, incorporamos uma nova fase após o fluxo de execução, denominada “Criação da Resposta Final”, que contém toda a lógica necessária para agrupar os resultados produzidos pelas tarefas anteriores em uma resposta que apresente o conteúdo e o formato esperados pelo usuário.

Para ilustrar concretamente cada etapa do fluxo, adota-se ao longo desta seção o seguinte *input* de referência:

Exemplo

Qual dos seguintes números é simultaneamente primo, par e maior que 2?

- A) 2
- B) 4
- C) 6
- D) Nenhuma das anteriores

Ao longo da descrição de cada fase, são apresentadas expressões que indicam quais informações compõem a entrada submetida ao modelo e qual saída é esperada. As nomenclaturas adotadas nessas expressões, como “Pergunta do usuário” ou “Template A.1”, representam os componentes lógicos necessários para montar o *prompt* de cada fase. O termo “Pergunta do usuário” refere-se ao *input* original fornecido ao sistema. Os termos na forma “Template X” referem-se a *prompts* fixos de instrução, cuja função é orientar o modelo sobre o que deve fazer naquela etapa específica. Já os termos na forma “Resultado Fase X” referem-se à saída produzida pelo modelo em uma etapa anterior, que pode ser reutilizada como entrada em etapas seguintes. Essas expressões não descrevem uma implementação concreta, mas sim a organização conceitual das informações que devem ser reunidas para que cada etapa do fluxo cumpra sua função.

A. Planejamento

O planejamento é o início de todo o fluxo, compreendendo duas etapas que preparam toda a estrutura de execução: a definição dos critérios que a resposta final deverá respeitar e a decomposição da pergunta em tarefas autônomas e verificáveis.

A.1 Definição dos critérios de aceite gerais

Essa etapa representa uma adição em relação ao paradigma original. No contexto de engenharia de software, cada tarefa concluída resultava em um *commit* que preservava o progresso diretamente no repositório, de modo que, ao término de todas as histórias de usuário, o produto final já estava pronto. No fluxo adaptado, entretanto, a conclusão de todas as tarefas não produz automaticamente uma saída




Figura 2. Visão geral do *Ralph Wiggum Loop* adaptado para resolução de perguntas em linguagem natural.

utilizável: após todas as tarefas serem concluídas, é necessário construir uma resposta final que consolide os resultados gerados. Os critérios de aceite gerais definem as regras que essa resposta deverá respeitar, abrangendo aspectos como o idioma a ser utilizado, o formato de apresentação esperado e os tópicos-chave que devem constar no conteúdo final.

Para executar essa etapa, é necessário montar um *template* de *prompt* fixo (Template A.1) que será combinado com a pergunta do usuário. Esse *template* deve instruir o modelo a analisar a pergunta recebida e, a partir dela, produzir uma lista de critérios de aceite que a resposta final deverá satisfazer. As instruções contidas no *template* devem solicitar ao modelo que identifique o idioma em que a pergunta foi formulada e determine em qual idioma a resposta deve ser redigida; que analise a estrutura da pergunta para definir o formato mais adequado de apresentação da resposta, como a seleção de uma alternativa, a produção de um texto dissertativo ou a apresentação de um valor numérico; e que extraia os tópicos-chave e restrições do enunciado que deverão obrigatoriamente constar na resposta. A saída esperada desse *template* é uma lista estruturada de critérios, onde cada critério define uma condição objetiva e verificável que a resposta final precisará atender. A relação de entrada e saída dessa etapa pode ser expressa como:

extPergunta do usuário + Template A.1
→ *Resultado Fase A.1*

Nessa expressão, “Pergunta do usuário” é o *input* original recebido pelo sistema e “Template A.1” é o *prompt* fixo de instrução descrito acima. O “Resultado Fase A.1” é

a lista de critérios de aceite gerais produzida pelo modelo, que deve ser armazenada localmente em arquivo ou na memória do programa para uso posterior na fase de Criação da Resposta Final.

Exemplo

Considerando o *input* de referência, o modelo deveria retornar uma lista de critérios como os seguintes.

Saída esperada do modelo:

“A pergunta deve ser respondida em Português do Brasil.”

“Responda somente a alternativa, sem conter explicações adicionais.”

“Garanta que o valor encontrado ao final corresponde a uma das alternativas fornecidas.”

A.2 Quebra em tarefas de objetivo único com critérios de aceite individuais

A segunda etapa do planejamento é responsável por quebrar a pergunta do usuário em pequenas tarefas autônomas. Cada tarefa precisa ter pelo menos um critério de aceite, isto é, uma condição que define o conteúdo esperado para que a tarefa possa ser considerada concluída. A ideia central é criar tarefas que gerem insumos capazes de, em conjunto, sustentar a construção da resposta final.

Para executar essa etapa, é necessário montar um *template* de *prompt* fixo (Template A.2) que será combinado com a pergunta do usuário. Esse *template* deve instruir o

modelo a decompor a pergunta em tarefas de objetivo único, onde cada tarefa possui uma única responsabilidade pontual, como “identificar os números primos” ou “identificar os números pares”, e nunca múltiplas responsabilidades simultâneas. As instruções devem orientar o modelo a descrever cada tarefa da forma mais detalhada possível, incluindo os dados de entrada sobre os quais ela opera e o resultado esperado, de modo a evitar desvios durante a resolução. O *template* deve também explicitar que o contexto de execução de uma tarefa não será transferido para a próxima, pois somente aprendizados pontuais sintetizados ao final de cada tarefa serão preservados; essa restrição precisa ser clara para que o modelo crie tarefas verdadeiramente autossuficientes. Por fim, o *template* deve exigir que cada tarefa contenha pelo menos um critério de aceite individual, formulado como condição objetiva e verificável que valide se a resposta gerada atende ao esperado, e que inclua critérios restritivos que impeçam a tarefa de extrapolar seu escopo, como “a resposta não deve tentar resolver a questão final” e “a resposta não deve avaliar condições pertencentes a outras tarefas”. A saída esperada é uma lista ordenada de tarefas, cada uma acompanhada de sua descrição e de seus critérios de aceite individuais. A relação de entrada e saída pode ser expressa como:

extPergunta do usuário + Template A.2

→ *Resultado Fase A.2*

Nessa expressão, “Pergunta do usuário” é o *input* original, “Template A.2” é o *prompt* fixo de instrução descrito acima, e “Resultado Fase A.2” é a lista de tarefas com seus respectivos critérios, que deve ser armazenada localmente em arquivo ou na memória do programa.

Exemplo

Considerando o *input* de referência, o modelo deveria retornar uma decomposição como a seguinte.

Saída esperada do modelo:

Tarefa 1

- Tarefa: “Dadas as opções (2, 4, 6), identifique quais desses números são primos.”
- Critérios de aceite:
 - “Deve retornar a lista de números primos encontrados nas alternativas.”
 - “Deve incluir uma breve explicação da regra de identificação de números primos.”
 - “A resposta não deve tentar resolver a questão final.”
 - “A resposta não deve avaliar nenhuma outra condição.”

Tarefa 2

- Tarefa: “Dadas as opções (2, 4, 6), identifique quais desses números são pares.”

• Critérios de aceite:

- “Deve retornar a lista de números pares encontrados nas alternativas.”
- “Deve incluir uma breve explicação da regra de identificação de números pares.”
- “A resposta não deve tentar resolver a questão final.”
- “A resposta não deve avaliar nenhuma outra condição.”

Tarefa 3

- Tarefa: “Dadas as opções (2, 4, 6), identifique quais desses números são estritamente maiores que 2.”
- Critérios de aceite:
 - “Deve retornar a lista de números maiores que 2 encontrados nas alternativas.”
 - “Deve incluir uma breve justificativa matemática para a comparação estabelecida.”
 - “A resposta não deve tentar resolver a questão final.”
 - “A resposta não deve avaliar nenhuma outra condição.”

B. Execução em Loop

A fase de execução preserva a estrutura iterativa do paradigma original, mas adapta o mecanismo de conclusão de cada unidade de trabalho. Na formulação original, a conclusão de uma história de usuário é verificada por meio da execução de testes automatizados e da análise dos critérios de aceite associados ao código produzido. No fluxo adaptado, como não há código a ser testado, o modelo simplesmente resolve a tarefa selecionada e, em seguida, verifica se o resultado satisfaz os critérios de aceite individuais definidos no planejamento. Caso os critérios não sejam atingidos, o modelo repete a resolução da mesma tarefa até que sejam satisfeitos.

Ao concluir uma tarefa com sucesso, o modelo realiza dois registros distintos com finalidades diferentes: (i) persiste a resposta aprovada em armazenamento local ou na memória da aplicação, em formato suficientemente estruturado para que cada resultado possa ser recuperado individualmente, servindo de insumo para a fase de Criação da Resposta Final; e (ii) extrai os aprendizados pontuais da execução, isto é, informações secas e objetivas descobertas ao longo das tentativas, que serão injetados no contexto da próxima tarefa como mecanismo de *Fresh Context*. É fundamental ressaltar que esses dois registros têm escopos completamente distintos: os resultados armazenados alimentam exclusivamente a fase de Criação da Resposta Final; os aprendizados pontuais têm papel restrito à Execução em Loop e não participam da construção da resposta final. Antes de iniciar a execução da tarefa seguinte, o contexto é reinicializado e os aprendizados acumulados

são injetados como primeira entrada do novo contexto, de forma estruturada e explícita. Esse mecanismo garante que o conhecimento relevante seja preservado sem que o ruído e as redundâncias das etapas anteriores sejam herdadas, mitigando ativamente o fenômeno de *context rot* [10].

Após cada tarefa concluída, o fluxo verifica programaticamente se ainda existem tarefas disponíveis na lista produzida pelo planejamento. Caso haja, uma nova iteração é iniciada: o contexto é reinicializado, os aprendizados acumulados são injetados e a próxima tarefa é selecionada. Caso contrário, o fluxo avança para a fase de Criação da Resposta Final, levando consigo apenas os resultados armazenados, sem os aprendizados pontuais. Essa verificação é puramente programática e não envolve chamada ao LLM.

B.1 Seleção da tarefa e resolução

Essa subseção corresponde às etapas B.1 e B.2 do fluxo ilustrado na Figura 2: a seleção da próxima tarefa disponível na lista gerada pelo planejamento (B.1) e sua subsequente resolução pelo modelo (B.2). Ao iniciar uma nova tarefa, e somente nesse momento, o contexto é reinicializado. Os aprendizados pontuais acumulados nas tarefas anteriores são injetados no início do novo contexto, antes da descrição da tarefa atual, garantindo continuidade do conhecimento relevante sem carregar o ruído das execuções anteriores. Na primeira tarefa do ciclo, não há aprendizados acumulados, de modo que o contexto inicial contém apenas a tarefa a ser resolvida.

Para executar essa etapa, é necessário montar um *template* de *prompt* fixo (Template B.1) que será combinado com a descrição da tarefa e, quando houver, com os aprendizados acumulados. Esse *template* deve instruir o modelo a focar exclusivamente no objetivo da tarefa que está sendo apresentada, sem tentar antecipar ou resolver etapas posteriores do fluxo. As instruções devem orientar o modelo a produzir uma resposta que cubra completamente o objetivo descrito na tarefa e que respeite os limites de escopo estabelecidos nos critérios de aceite individuais. O contexto de entrada é montado a partir de três componentes: os aprendizados pontuais acumulados das tarefas anteriores (quando houver), a descrição completa da tarefa selecionada conforme definida no planejamento, e o próprio Template B.1. A saída esperada é a resolução completa da tarefa, aqui chamada de Resultado Preliminar B. A relação de entrada e saída pode ser expressa como:

$$\begin{aligned} & \text{extAprendizados Acumulados} \\ & + \text{Tarefa Selecionada} + \text{Template B.1} \\ & \longrightarrow \text{Resultado Preliminar B} \end{aligned}$$

Nessa expressão, “Aprendizados Acumulados” são os fatos objetivos extraídos das tarefas já concluídas (vazio na primeira tarefa), “Tarefa Selecionada” é a descrição completa da tarefa com seus critérios de aceite conforme definidos no Resultado Fase A.2, e “Template B.1” é o *prompt* fixo de instrução descrito acima. O “Resultado

Preliminar B” é a resposta produzida pelo modelo para a tarefa, que seguirá para verificação na etapa seguinte.

Exemplo

Considerando a Tarefa 1 como primeira tarefa do ciclo, o contexto não contém aprendizados acumulados.

Saída esperada do modelo:

“Entre as alternativas (2, 4, 6), somente o número 2 é primo. Um número primo é aquele divisível exclusivamente por 1 e por ele mesmo. O número 4 possui divisores adicionais (1, 2 e 4) e o 6 também (1, 2, 3 e 6), portanto nenhum dos dois é primo. Resultado: [2].”

B.2 Verificação dos critérios de aceitação da tarefa

Essa etapa verifica se o Resultado Preliminar B produzido na etapa anterior atende a todos os critérios de aceite individuais associados à tarefa em execução. Trata-se de um mecanismo de controle de qualidade interno: se todos os critérios forem atendidos, o fluxo avança para o armazenamento do resultado; caso contrário, a tarefa é reapresentada ao modelo para uma nova tentativa. É importante destacar que, ao contrário do que ocorre na transição entre tarefas distintas, o contexto *não* é reinicializado durante as tentativas de repetição de uma mesma tarefa. Essa escolha é intencional e também é usada no *Ralph Loop* original: a tentativa anterior, com os critérios não satisfeitos explicitamente sinalizados, permanece no contexto e auxilia o modelo a identificar o que deve ser corrigido na próxima execução.

Para executar essa etapa, é necessário montar um *template* de *prompt* fixo (Template B.2) que será combinado com o Resultado Preliminar B e com os critérios de aceite individuais da tarefa. Esse *template* deve instruir o modelo a avaliar o resultado recebido contra cada critério de aceite, um por um, identificando para cada critério se ele foi atendido ou não e justificando essa decisão. As instruções devem exigir que a saída contenha uma decisão final estruturada (aprovado ou reprovado) e, em caso de reprovação, a lista explícita dos critérios que não foram satisfeitos. A relação de entrada e saída pode ser expressa como:

$$\begin{aligned} & \text{extResultado Preliminar B} \\ & + \text{Critérios da Tarefa} + \text{Template B.2} \\ & \longrightarrow \text{Decisão (Aprovado / Reprovado)} \end{aligned}$$

Nessa expressão, “Resultado Preliminar B” é a resposta produzida na etapa anterior, “Critérios da Tarefa” são os critérios de aceite individuais definidos no Resultado Fase A.2 para a tarefa em questão, e “Template B.2” é o *prompt* fixo de instrução descrito acima.

Exemplo

Cenário de aprovação. Avaliando o resultado da Tarefa 1 contra seus critérios de aceite.

Saída esperada do modelo:

- “Deve retornar a lista de números primos.”
Atendido: a lista [2] foi retornada.
- “Deve incluir explicação da regra de identificação de primos.”
Atendido: a explicação por divisores foi fornecida.
- “A resposta não deve tentar resolver a questão final.”
Atendido: o modelo não antecipou a resposta.
- “A resposta não deve avaliar nenhuma outra condição.”
Atendido: somente a primalidade foi avaliada.

Decisão: **Aprovado.**

O fluxo avança para o armazenamento do resultado.

Cenário de reprovação e nova tentativa. Considere a Tarefa 2 (“identifique quais números são pares”). O aprendizado acumulado da Tarefa 1 já está no contexto: “O único número primo entre as alternativas é o 2”. Suponha que o modelo produza na primeira tentativa:

Saída esperada do modelo:

“Todos os números 2, 4 e 6 são pares, pois são divisíveis por 2. No entanto, como apenas o 2 é primo (identificado anteriormente) e o 2 não é maior que 2, nenhuma alternativa satisfaz simultaneamente as três condições. Portanto, a resposta é D) Nenhuma das anteriores.”

Avaliando esse resultado contra os critérios da Tarefa 2:

Saída esperada do modelo:

- “Deve retornar a lista de números pares.”
Atendido: os três números foram identificados.
- “Deve incluir explicação da regra de identificação de pares.”
Atendido: a divisibilidade por 2 foi mencionada.
- “A resposta não deve tentar resolver a questão final.”
Não atendido: o modelo antecipou a resposta final.
- “A resposta não deve avaliar nenhuma outra condição.”
Não atendido: o modelo cruzou condições de outras tarefas.

Decisão: **Reprovado.**

O fluxo retorna à resolução da Tarefa 2, mantendo o contexto com a tentativa reprovada e os critérios não satisfeitos identificados. Na segunda tentativa, com o *feedback* anterior no contexto, o modelo retorna:

Saída esperada do modelo:

“Entre as alternativas (2, 4, 6), todos os três números são pares, pois cada um deles é divisível por 2 sem deixar resto ($2 \div 2 = 1$, $4 \div 2 = 2$, $6 \div 2 = 3$). Resultado: [2, 4, 6].”

Todos os critérios da Tarefa 2 são agora atendidos. Decisão: **Aprovado.** O fluxo avança.

B.3 Armazenamento do resultado

Quando a resposta de uma tarefa é aprovada na verificação dos critérios de aceite, ela é persistida localmente. Somente essa resposta aprovada é armazenada: todo o ruído gerado pelos ciclos de tentativa anteriores, incluindo respostas reprovadas, histórico de verificações e *feedback* intermediário, não é persistido e será descartado quando o contexto for reinicializado na transição para a próxima tarefa. O armazenamento é indexado por tarefa, de modo que cada resultado possa ser recuperado individualmente pela fase de Criação da Resposta Final. Esses resultados armazenados são o único insumo factual utilizado na fase de Criação da Resposta Final para a construção da resposta ao usuário; os aprendizados pontuais, tratados na etapa seguinte, têm escopo restrito à Execução em Loop e não participam da criação da resposta final.

Do ponto de vista prático, a resposta aprovada na etapa anterior é persistida no armazenamento local ou na memória da aplicação, indexada pelo identificador da tarefa. O formato de armazenamento é uma decisão de implementação, sendo que qualquer estrutura que permita recuperar individualmente o resultado de cada tarefa é adequada. Não há chamada adicional ao LLM nessa etapa. A relação de entrada e saída pode ser expressa como:

extResposta Aprovada → *Armazenamento local*

Exemplo

A Tarefa 2 exigiu duas tentativas antes de ser aprovada. Somente a segunda é armazenada. A primeira tentativa reprovada, aquela que antecipou indevidamente a resposta final, permanece apenas no contexto ativo durante o ciclo de repetição e é descartada na reinicialização. Ao término da Execução em Loop, o armazenamento contém exclusivamente as respostas aprovadas de cada tarefa:

- Tarefa 1: “Entre as alternativas (2, 4, 6), somente o número 2 é primo. Um número primo é aquele divisível exclusivamente por 1 e por ele mesmo. O número 4 possui divisores adicionais (1, 2 e 4) e o 6 também (1, 2, 3 e 6), portanto nenhum dos dois é

primo. Resultado: [2].”

- Tarefa 2: “Entre as alternativas (2, 4, 6), todos os três números são pares, pois cada um deles é divisível por 2 sem deixar resto ($2 \div 2 = 1$, $4 \div 2 = 2$, $6 \div 2 = 3$). Resultado: [2, 4, 6].”
- Tarefa 3: “Os números estritamente maiores que 2 entre as alternativas são 4 e 6. O número 2 não satisfaz essa condição pois $2 > 2$ é falso. Resultado: [4, 6].”

Esse conjunto é entregue à fase de Criação da Resposta Final como base exclusiva para a construção da resposta.

B.4 Armazenamento dos aprendizados pontuais

Os aprendizados pontuais funcionam como as “anotações internas” do fluxo de *thinking*: são fatos secos e objetivos descobertos durante a execução de uma tarefa que podem ser úteis para resolver as tarefas subsequentes. Exemplos típicos incluem o resultado de um cálculo intermediário, uma fórmula identificada, uma conversão de unidade de medida, um valor recuperado após busca ou uma lista de candidatos filtrados. Em todos os casos, o registro deve conter apenas a informação em si, sem qualquer contexto de como ela foi obtida. A extração de aprendizados considera o contexto completo da tarefa, incluindo as tentativas reprovadas, pois fatos úteis podem ter emergido mesmo em execuções que não passaram na verificação de critérios. Os aprendizados pontuais têm escopo estritamente restrito à Execução em Loop: são injetados no início do contexto de cada nova tarefa para subsidiar a resolução, mas não são incluídos, em nenhuma hipótese, na fase de Criação da Resposta Final.

Para executar essa etapa, é necessário montar um *template* de *prompt* fixo (Template B.4) que será aplicado sobre o contexto completo da tarefa concluída. Esse *template* deve instruir o modelo a percorrer todo o conteúdo gerado durante a resolução da tarefa, incluindo tentativas reprovadas e a resposta aprovada, e a identificar quaisquer fatos concretos e objetivos que possam ser úteis nas próximas tarefas. As instruções devem exigir que os aprendizados sejam registrados como sentenças curtas e factuais, sem narrativa, sem justificativas e sem referência ao processo de resolução; cada aprendizado deve conter apenas o fato em si. A saída esperada é uma lista compacta de fatos pontuais. A relação de entrada e saída dessa etapa pode ser expressa como:

extContexto Completo da Tarefa
+ *Template B.4*
→ *Aprendizados Pontuais*

Nessa expressão, “Contexto Completo da Tarefa” é o histórico integral da execução da tarefa, contendo todas as tentativas (reprovadas e aprovada) e suas respectivas

verificações. “Template B.4” é o *prompt* fixo de instrução descrito acima. “Aprendizados Pontuais” são os fatos extraídos, que são adicionados à Memória Acumulada. A Memória Acumulada é simplesmente o local onde os aprendizados pontuais de todas as tarefas já concluídas vão se acumulando ao longo do processo; a cada nova tarefa iniciada, todo o conteúdo dessa memória é injetado no início do novo contexto. Essa memória não é utilizada na construção da resposta final.

Exemplo

Após a conclusão das três tarefas, a Memória Acumulada conteria algo como o seguinte.

Saída esperada do modelo:

“Primos entre (2, 4, 6): [2]”
“Pares entre (2, 4, 6): [2, 4, 6]”
“Maiores que 2 entre (2, 4, 6): [4, 6]”

Esse bloco compacto seria injetado no início do contexto de uma eventual Tarefa 4 e não é utilizado na construção da resposta final.

Como contraponto, o trecho a seguir ilustra o formato **inválido** de aprendizado, por ser verboso e conter contexto desnecessário:

Inválido: “Durante a execução da Tarefa 2, após uma tentativa reprovada por ter antecipado a resposta final, foi identificado que todos os números 2, 4 e 6 são pares, verificando a divisibilidade de cada um por 2.”

O aprendizado pontual válido extrai apenas o fato: “Pares entre (2, 4, 6): [2, 4, 6]”.

A distinção entre resultado armazenado (etapa anterior) e aprendizado pontual é estrutural e intencional. O resultado é a resposta completa e verificada da tarefa, destinada à síntese da fase de Criação da Resposta Final. O aprendizado é um fragmento seco de fato, destinado exclusivamente a subsidiar a execução das tarefas seguintes dentro do loop.

C. Criação da Resposta Final

A terceira fase constitui uma adição exclusiva do fluxo adaptado, sem correspondência direta na formulação original. No *Ralph Wiggum Loop* concebido para engenharia de software, o produto final é o próprio código implementado e versionado ao longo das histórias; não há, portanto, necessidade de uma etapa de síntese do conteúdo e geração de resposta. No fluxo adaptado, os resultados das tarefas individuais são fragmentos de raciocínio que precisam ser compilados em uma resposta coesa e completa.

Após o encerramento do loop, o modelo compila os resultados armazenados e verifica se as informações produzidas são suficientes para satisfazer todos os critérios de aceite gerais definidos no planejamento. Se os critérios forem integralmente atendidos, o modelo constrói a resposta

final e a retorna ao usuário. Caso contrário, o sistema infere que o planejamento inicial foi insuficiente para cobrir todos os aspectos da pergunta e inicia uma fase de *Planejamento Adicional*: o modelo identifica os critérios ainda não atendidos, cria novas tarefas individuais para supri-los e retorna à fase de Execução em Loop. Esse mecanismo garante que lacunas de planejamento sejam identificadas e corrigidas antes que a resposta final seja construída, preservando a completude e a coerência da saída.

C.1 Compilação dos resultados e verificação dos critérios gerais

Essa etapa reúne todos os resultados armazenados durante a Execução em Loop e verifica se o conjunto de informações produzido é suficiente para satisfazer cada um dos critérios de aceite gerais definidos na etapa A.1. A distinção central em relação à verificação realizada na Execução em Loop é o escopo da avaliação: enquanto lá a verificação é local, com cada tarefa avaliada contra seus próprios critérios individuais, aqui a avaliação é global, e o conjunto completo de resultados é considerado para determinar se é possível construir uma resposta final completa e correta.

Para executar essa etapa, é necessário montar um *template* de *prompt* fixo (Template C.1) que será combinado com os resultados armazenados e com os critérios gerais definidos na etapa A.1. Esse *template* deve instruir o modelo a listar os resultados de cada tarefa e então avaliar, critério geral por critério geral, se os resultados em conjunto fornecem informação suficiente para satisfazê-los. As instruções devem exigir que a saída contenha uma decisão para cada critério (atendível ou não atendível) e uma decisão final estruturada (aprovado ou reprovado), com identificação explícita dos critérios não atendidos quando for o caso. A relação de entrada e saída pode ser expressa como:

extResultados Armazenados
 + Critérios Gerais (A.1) + Template C.1
 → Decisão (Aprovado / Reprovado)

Nessa expressão, “Resultados Armazenados” são as respostas aprovadas de todas as tarefas concluídas, “Critérios Gerais (A.1)” são os critérios de aceite gerais produzidos no Resultado Fase A.1, e “Template C.1” é o *prompt* fixo de instrução descrito acima.

Exemplo

Cenário de aprovação. Com os três resultados disponíveis ao término do loop, a avaliação contra os critérios gerais de A.1 produz:

Saída esperada do modelo:

Resultados disponíveis:

- Tarefa 1: “Entre as alternativas (2, 4, 6), somente o número 2 é primo. Um número primo é aquele divisível exclusivamente

por 1 e por ele mesmo. O número 4 possui divisores adicionais (1, 2 e 4) e o 6 também (1, 2, 3 e 6), portanto nenhum dos dois é primo. Resultado: [2].”

- Tarefa 2: “Entre as alternativas (2, 4, 6), todos os três números são pares, pois cada um deles é divisível por 2 sem deixar resto ($2 \div 2 = 1$, $4 \div 2 = 2$, $6 \div 2 = 3$). Resultado: [2, 4, 6].”
- Tarefa 3: “Os números estritamente maiores que 2 entre as alternativas são 4 e 6. O número 2 não satisfaz essa condição pois $2 > 2$ é falso. Resultado: [4, 6].”

Avaliação dos critérios gerais:

- “A pergunta deve ser respondida em Português do Brasil.”
Atendível: todos os resultados estão em português.
- “Responda somente a alternativa, sem explicações adicionais.”
Atendível: os dados disponíveis permitem identificar a alternativa correta.
- “O valor encontrado deve corresponder a uma das alternativas.”
Atendível: primo $\cap$ par $\cap$ maior que 2 = $\emptyset$, o que corresponde à alternativa D.

Decisão: **Aprovado.**

O fluxo avança para a construção da resposta final.

Cenário de reprovação. Considere uma variação em que os critérios gerais incluam: “A resposta deve ser sustentada por uma verificação explícita de qual conjunto de alternativas satisfaz simultaneamente todas as condições enunciadas.” Os três resultados cobrem cada condição individualmente, mas nenhuma tarefa realizou a análise de interseção.

Saída esperada do modelo:

- “Verificação explícita da interseção dos conjuntos.”
Não atendido: nenhuma tarefa realizou a verificação combinada das três condições.

Decisão: **Reprovado.**

O fluxo avança para o Planejamento Adicional.

C.2 Planejamento Adicional

Quando os critérios gerais não são atendidos, o Planejamento Adicional funciona como uma extensão da fase A.2: identifica as lacunas específicas nos resultados disponíveis e cria novas tarefas individuais para supri-las. Diferentemente do planejamento inicial, que parte da pergunta do

usuário sem qualquer contexto de execução, o Planejamento Adicional tem acesso ao conjunto de resultados já produzidos e ao mapeamento preciso dos critérios que ainda não foram satisfeitos. Essa informação torna as novas tarefas mais pontuais e direcionadas, evitando retrabalho sobre o que já foi verificado. As novas tarefas são adicionadas à fila de execução e o fluxo retorna à etapa B.1, agora com o contexto dos aprendizados acumulados de todas as tarefas anteriores disponível.

Para executar essa etapa, é necessário montar um *template* de *prompt* fixo (Template C.2) que será combinado com os critérios gerais não atendidos e com os resultados já armazenados. Esse *template* deve instruir o modelo a identificar os critérios gerais que não foram satisfeitos, raciocinar sobre que tipo de informação adicional seria necessária para satisfazê-los e formular novas tarefas de objetivo único com critérios de aceite individuais, seguindo o mesmo padrão estabelecido na fase A.2. A relação de entrada e saída pode ser expressa como:

extCritérios Não Atendidos
 + *Resultados Armazenados* + *Template C.2*
 → *Novas Tarefas*

Nessa expressão, “Critérios Não Atendidos” são os critérios gerais identificados como não satisfeitos na etapa anterior, “Resultados Armazenados” são as respostas aprovadas de todas as tarefas já concluídas, e “Template C.2” é o *prompt* fixo de instrução descrito acima.

Exemplo

A partir da reprovação identificada no cenário anterior, o modelo produziria novas tarefas como a seguinte.

Saída esperada do modelo:

Tarefa 4

- Tarefa: “Dadas as listas já identificadas — primos: [2]; pares: [2, 4, 6]; maiores que 2: [4, 6] —, determine quais números aparecem simultaneamente nas três listas.”
- Critérios de aceite:
 - “Deve retornar o resultado da interseção das três listas, podendo ser um conjunto vazio.”
 - “Deve apresentar justificativa explicando a presença ou ausência de cada candidato em cada lista.”
 - “A resposta não deve construir a resposta final ao usuário.”

Essa nova tarefa é enviada à Execução em Loop. Com os aprendizados de T1, T2 e T3 injetados no contexto, o modelo executa a Tarefa 4.

Saída esperada do modelo:

“Verificando a interseção: primos [2] $\cap$ pares [2, 4, 6] $\cap$ maiores que 2 [4, 6]. O número 2 está em {primos} e {pares}, mas não em {maiores que 2} (pois $2 > 2$ é falso). Os números 4 e 6 estão em {pares} e {maiores que 2}, mas não em {primos}. Resultado da interseção: {} (conjunto vazio — nenhum número satisfaz simultaneamente as três condições).”

Após a aprovação da Tarefa 4, o fluxo retorna à compilação dos resultados para nova verificação. Desta vez, com quatro resultados disponíveis, todos os critérios gerais são atendidos e o fluxo avança para a construção da resposta final.

O mecanismo de Planejamento Adicional pode ocorrer mais de uma vez caso as novas tarefas criadas ainda não sejam suficientes para satisfazer todos os critérios gerais. A cada retorno à compilação, o conjunto de resultados disponíveis é maior, convergindo progressivamente para a completude.

C.3 Construção da resposta final

Com todos os critérios gerais satisfeitos, o modelo compõe a resposta final ao usuário. Essa etapa não realiza novo raciocínio analítico sobre o problema: seu objetivo é exclusivamente organizar e apresentar os resultados já produzidos no formato e idioma definidos pelos critérios gerais (Resultado Fase A.1). A distinção entre esta etapa e as anteriores é deliberada: ao separar o raciocínio analítico, realizado de forma incremental e verificada durante a Execução em Loop, da síntese da resposta final, reduz-se o risco de que a fase de apresentação introduza inferências não verificadas ou contradiga os resultados produzidos.

Para executar essa etapa, é necessário montar um *template* de *prompt* fixo (Template C.3) que será combinado com os resultados compilados e com os critérios gerais. Esse *template* deve instruir o modelo a utilizar exclusivamente os resultados armazenados como base factual para compor a resposta, sem introduzir raciocínio ou informações novas que não estejam amparadas por esses resultados. As instruções devem também orientar o modelo a respeitar o formato e o idioma definidos nos critérios gerais. A relação de entrada e saída pode ser expressa como:

extResultados Compilados
 + *Critérios Gerais (A.1)* + *Template C.3*
 → *Resposta Final*

Nessa expressão, “Resultados Compilados” são as respostas aprovadas de todas as tarefas, “Critérios Gerais (A.1)” são os critérios definidos no Resultado Fase A.1, e “Template C.3” é o *prompt* fixo de instrução descrito acima.

Exemplo

Em ambos os cenários (aprovação direta com três tarefas ou com Planejamento Adicional em quatro tarefas), os resultados indicam que $\text{primo} \cap \text{par} \cap \text{maior que } 2 = \emptyset$. Respeitando os critérios gerais, a resposta final produzida é:

Saída esperada do modelo:

D) Nenhuma das anteriores

Essa resposta é então retornada ao usuário, encerrando o fluxo.

IV. Metodologia de avaliação

A metodologia de avaliação visa mensurar o impacto do *harness* proposto na acurácia de modelos de linguagem em tarefas de raciocínio geral, comparando sistematicamente a inferência direta com a inferência orquestrada. Para essa validação, os experimentos são conduzidos com três modelos da família Llama 3.1, nas variantes de 8B, 70B e 405B parâmetros, escolhidos por representarem uma progressão controlada de escala computacional dentro de uma mesma arquitetura base. Essa escolha permite isolar o efeito da orquestração do efeito da escala, avaliando se os ganhos introduzidos pelo *harness* se manifestam de forma consistente independentemente do tamanho do modelo.

Para cada variante, são comparadas duas configurações de inferência: (i) uma chamada direta ao modelo, na qual toda a resposta é produzida em uma única etapa de inferência sem qualquer processamento auxiliar; e (ii) a mesma inferência mediada pelo *harness* proposto, que aplica o fluxo completo de Planejamento, Execução em Loop e Criação da Resposta Final descrito na seção de metodologia, sem o uso de ferramentas externas. O desempenho é mensurado por meio de questões amostradas das bases MMLU [13] e GPQA [14], escolhidas por seu elevado rigor acadêmico e por serem amplamente adotadas como referência na literatura de avaliação de LLMs. A métrica principal é a acurácia, obtida pela correspondência estrita entre a alternativa selecionada pelo sistema e o gabarito oficial.

Para contextualizar os resultados obtidos em relação ao estado da arte, os valores de acurácia dos modelos Llama 3.1 nas duas configurações são comparados com os resultados de inferência direta já publicados para Claude Sonnet 4.6 e GPT 5.4 nos mesmos *benchmarks*. Esses modelos comerciais não são submetidos ao *harness* proposto: sua função é exclusivamente estabelecer um ponto de referência de mercado que permita situar o desempenho alcançado pela abordagem proposta em relação a sistemas modernos de grande escala.

Referências

- [1] Y. Lee, R. Nair, Q. Zhang, K. Lee, O. Khattab e C. Finn, “Meta-Harness: End-to-End Optimization of Model Harnesses,” *arXiv preprint arXiv:2603.28052*, 2026.
- [2] J. Wei et al., “Chain-of-Thought Prompting Elicits Reasoning in Large Language Models,” *arXiv preprint arXiv:2201.11903*, 2022.
- [3] S. Yao et al., “Tree of Thoughts: Deliberate Problem Solving with Large Language Models,” *arXiv preprint arXiv:2305.10601*, 2023.
- [4] D. Zhou et al., “Least-to-most prompting enables complex reasoning in large language models,” *arXiv preprint arXiv:2205.10625*, 2022.
- [5] S. Yao et al., “ReAct: Synergizing Reasoning and Acting in Language Models,” *arXiv preprint arXiv:2210.03629*, 2022.
- [6] N. Shinn, F. Cassano, B. Labash, A. Gopinath, K. Narasimhan e S. Yao, “Reflexion: Language Agents with Verbal Reinforcement Learning,” *arXiv preprint arXiv:2303.11366*, 2023.
- [7] X. Chen, M. Lin, N. Schärli e D. Zhou, “Teaching Large Language Models to Self-Debug,” *arXiv preprint arXiv:2304.05128*, 2023.
- [8] A. Madaan et al., “Self-Refine: Iterative Refinement with Self-Feedback,” *arXiv preprint arXiv:2303.17651*, 2023.
- [9] N. F. Liu et al., “Lost in the Middle: How Language Models Use Long Contexts,” *Transactions of the Association for Computational Linguistics*, v. 12, pp. 277–294, 2024.
- [10] K. Hong, A. Troynikov e J. Huber, “Context Rot: How Increasing Input Tokens Impacts LLM Performance,” Chroma, rel. técn., jul. de 2025. endereço: <https://trychroma.com/research/context-rot>
- [11] G. Ghuntley, *Ralph Loop: A Structured Orchestration Pattern for LLM Inference*, Online. Disponível em: <https://ghuntley.com/specs/ralph/>, Acesso em: abr. 2026, 2025.
- [12] Z. Wang et al., “Beyond the Strongest LLM: Multi-Turn Multi-Agent Orchestration vs. Single LLMs on Benchmarks,” *arXiv preprint arXiv:2509.23537*, 2025.
- [13] D. Hendrycks et al., “Measuring Massive Multitask Language Understanding,” em *International Conference on Learning Representations*, 2021.
- [14] D. Rein et al., “GPQA: A Graduate-Level Google-Proof Q&A Benchmark,” *arXiv preprint arXiv:2311.12022*, 2023.
- [15] T. B. Brown et al., “Language Models are Few-Shot Learners,” em *Advances in Neural Information Processing Systems*, 2020.
- [16] A. Vaswani et al., “Attention is All You Need,” em *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [17] W. X. Zhao et al., “A Survey of Large Language Models,” *arXiv preprint arXiv:2303.18223*, 2023.

Tabela I. Cronograma das atividades do projeto.

Atividade	fev	mar	abr	mai	jun	jul	ago	set	out	nov
Revisão bibliográfica e refinamento da proposta	X	X	X	X						
Definição da arquitetura		X	X	X	X					
Desenvolvimento do Paper		X	X	X	X	X	X	X	X	X
Implementação prática do código				X	X	X	X	X	X	
Análise final									X	X

- [18] M. Zaharia et al., *The Shift from Models to Compound AI Systems*, Berkeley Artificial Intelligence Research Blog. Disponível em: <https://bair.berkeley.edu/blog/2024/02/18/compound-ai-systems/>, Acesso em: mai. 2026, 2024.
- [19] Anthropic, *Claude Code*, <https://www.anthropic.com/claude-code>, 2026.
- [20] M. Chen et al., “Evaluating Large Language Models Trained on Code,” *arXiv preprint arXiv:2107.03374*, 2021.
- [21] *OpenCLI*, <https://opencli.ai/>, 2026.
- [22] T. Khot et al., “Decomposed prompting: A modular approach for solving complex tasks,” *arXiv preprint arXiv:2210.02406*, 2022.
- [23] L. Wang et al., “Plan-and-solve prompting: Improving zero-shot chain-of-thought reasoning by large language models,” *arXiv preprint arXiv:2305.04091*, 2023.
- [24] C. McComb et al., “Supervising Ralph Wiggum: Exploring a Metacognitive Co-Regulation Agentic AI Loop for Engineering Design,” *arXiv preprint arXiv:2603.24768*, 2026.