

# Sistemas Compostos de IA: Otimização de Respostas em Benchmarks Objetivos por meio de Orquestração Baseada no Ralph Loop

**Hugo Emílio Nomura, Pedro Henrique Correia de Oliveira, Pedro Henrique Satoru Lima Takahashi, Vitor Monteiro Vianna**

Ciência da Computação – Centro Universitário FEI, campus São Paulo

unifhnomura@fei.edu.br, unifpoliveira@fei.edu.br, unifptakahashi@fei.edu.br, unievvianna@fei.edu.br

**Orientador: Charles Henrique Porto Ferreira**

Departamento de Ciência da Computação, Centro Universitário FEI

cferreira@fei.edu.br

**Resumo:** Embora os *Large Language Models* (LLMs) continuem operando como geradores de texto, sua evolução recente não depende apenas do aumento de capacidade ou da complexidade matemática. Soluções modernas incorporam planejamento, refinamento e ciclos iterativos de raciocínio para melhorar a qualidade e a consistência das saídas. No entanto, o uso prolongado desses mecanismos amplia a janela de contexto e pode causar degradação de informação (*context rot*), reduzindo a confiabilidade das respostas.

Este trabalho propõe adaptar os princípios do Ralph Wiggum Loop para cenários gerais de *benchmarking*, com o objetivo de melhorar respostas por meio de chamadas iterativas ao próprio modelo, sem ferramentas externas. Para mitigar o *context rot*, a arquitetura preserva um comportamento *stateless* entre as fases, mantendo apenas os artefatos estritamente necessários a cada etapa.

O impacto empírico da abordagem será avaliado com os *benchmarks* MMLU e GPQA, comparando a acurácia de chamadas diretas ao modelo com a de execuções mediadas pelo *harness* proposto.

**Palavras-chaves:** *Large Language Models* (LLMs). Ralph Wiggum Loop. Sistemas Compostos de IA. Engenharia de Prompt. Decaimento de Contexto (*context rot*).

## 1. Introdução

Os *Large Language Models* (LLMs) consolidaram-se como o núcleo de uma nova geração de sistemas capazes de executar tarefas complexas de processamento de linguagem natural, incluindo geração de texto, resolução de problemas, planejamento intermediário e suporte à tomada de decisão. Apesar dessas capacidades, os modelos que servem como base para esses sistemas continuam sendo, em essência, geradores probabilísticos de *tokens*, operando a partir de uma entrada de texto e retornando como saída outro texto. Nesse contexto, parte significativa da evolução recente dos sistemas baseados em LLMs passou a ocorrer não apenas nos próprios modelos, mas também nas estruturas responsáveis por organizar sua utilização prática. Trabalhos recentes, como [1], afirmam que “The performance of large language model (LLM) systems depends not only on model weights, but also on their harness: the code that determines what information to store, retrieve, and present to the model”, evidenciando o papel dos chamados *harnesses* na ampliação das capacidades desses sistemas. Ferramentas modernas, como o *ChatGPT*, incorporam tais mecanismos para adicionar camadas de coordenação, decomposição de tarefas, validação intermediária e orquestração de múltiplas inferências, permitindo que o modelo execute fluxos significativamente mais sofisticados do que uma única chamada linear de entrada e saída.

Abordagens baseadas em uma única chamada ao modelo, nas quais toda a resposta é produzida em uma única

etapa de inferência, apresentam limitações importantes em tarefas que exigem raciocínio complexo, múltiplas etapas de decisão ou validações intermediárias. Como resposta a esse problema, diferentes linhas de pesquisa passaram a explorar fluxos estruturados de *thinking*, nos quais o processo de inferência é explicitamente decomposto em etapas sucessivas de raciocínio, planejamento, execução e refinamento. Trabalhos baseados em *Chain-of-Thought* [2], *Tree of Thoughts* [3] e na técnica de *Least-to-Most* [4] demonstram que a decomposição explícita do raciocínio favorece significativamente a resolução de tarefas complexas. De maneira semelhante, abordagens como *ReAct* [5] combinam raciocínio e ações iterativas, enquanto métodos como *Reflexion* [6], *Self-Debugging* [7] e *Self-Refine* [8] exploram ciclos sucessivos de avaliação, crítica e refinamento da própria resposta gerada. Em conjunto, esses trabalhos indicam que ganhos de desempenho não dependem exclusivamente do tamanho do modelo ou da quantidade de *tokens* gerados, mas também da maneira como o processo de inferência é estruturado, coordenado e validado ao longo da execução.

Apesar dos ganhos observados nessas arquiteturas iterativas compostas por agentes, ciclos de reflexão ou *pipelines* sucessivos, tais abordagens também introduzem novos desafios relacionados ao gerenciamento do contexto acumulado durante a inferência. Em muitos desses sistemas, o histórico completo de interações permanece armazenado na janela de contexto ao longo de toda a execução como mecanismo de preservação da continuidade do raciocínio.

Embora essa estratégia favoreça rastreabilidade e coerência entre etapas intermediárias, ela também aumenta progressivamente a dificuldade de recuperação de informações relevantes conforme o contexto cresce. Liu et al. [9], por exemplo, demonstram que ocorre perda de desempenho em tarefas que exigem localizar informações relevantes em sequências extensas. Trabalhos recentes também passaram a discutir fenômenos associados à degradação progressiva do contexto em execuções longas, incluindo compressão implícita de informações, perda de relevância contextual e aumento de inconsistências ao longo da inferência. Esses efeitos vêm sendo frequentemente associados, ao conceito de *context rot*, termo utilizado por Hong et al. [10] para descrever a degradação gradual da qualidade das respostas conforme o volume de contexto acumulado aumenta.

Além do avanço acadêmico dessas abordagens, a indústria de engenharia de software também passou a investir intensamente em arquiteturas de *deep thinking* e em *harnesses* especializados para ampliar a capacidade operacional de LLMs em tarefas complexas de desenvolvimento. Ferramentas recentes, como *Claude Code*, *GPT Codex*, *OpenCLI* e *Devin*, exemplificam essa tendência ao combinar planejamento, decomposição de tarefas, validação iterativa e execução coordenada de múltiplas inferências. Nesse contexto, uma das abordagens que ganhou notoriedade foi o *Ralph Wiggum Loop* [11], popularizado por Geoffrey Huntley no contexto de engenharia de software. Em sua formulação original, entretanto, o modelo não foi concebido para cenários generalistas, mas especificamente para fluxos de desenvolvimento baseados em conceitos próprios da engenharia de software, como definição de funcionalidades, requisitos, critérios de aceite e integração com sistemas de versionamento, como o *Git*. Ainda assim, sua estrutura apresenta dois princípios centrais relevantes para os problemas discutidos na literatura de LLMs: a decomposição do processo em tarefas independentes, reduzindo a necessidade de reaproveitamento contínuo do contexto entre etapas, e a execução iterativa de cada tarefa até que critérios mínimos de qualidade sejam satisfatoriamente atingidos.

Este trabalho parte de três premissas consolidadas na literatura: que abordagens de *thinking* podem melhorar a qualidade das respostas de LLMs em cenários específicos, como os de tarefas complexas; que tais abordagens introduzem problemas associados ao crescimento excessivo do contexto acumulado, fenômeno descrito como *context rot*; e que o *Ralph Wiggum Loop* [11], concebido por Huntley para fluxos de engenharia de software, oferece princípios estruturais capazes de mitigar esse problema por meio de decomposição de tarefas e isolamento contextual entre etapas. A partir dessas premissas, propõe-se a adaptação do *Ralph Wiggum Loop* para um contexto generalista de resolução de tarefas em linguagem natural a partir de um *prompt* de entrada fornecido pelo usuário. Diferentemente da proposta original, centrada em desenvolvimento de software, definições de funcionalidades, critérios de aceite baseados em requisitos funcionais e integração com ferramentas de versionamento (como *Git*), a adaptação proposta investiga se, ao adaptar a estrutura do *Ralph Wiggum Loop* a um fluxo

completo de *thinking* aplicável à resolução de perguntas gerais e à exploração de problemas diversos e de diferentes complexidades, também haverá melhora na qualidade dessas respostas quando comparadas a uma única etapa de inferência.

Para avaliar essa hipótese de maneira objetiva, reproduzível e quantitativa, o trabalho compara diretamente duas estratégias de inferência: (i) uma chamada tradicional a um modelo de LLM, na qual toda a resposta é produzida em uma única etapa de inferência; e (ii) uma execução mediada pelo *harness* proposto, que adapta o *Ralph Wiggum Loop* para cenários generalistas. O objetivo experimental é medir em que magnitude a aplicação desse fluxo estruturado de *thinking* melhora a qualidade das respostas em relação à inferência singular tradicional. Para permitir essa quantificação, os experimentos utilizam *benchmarks* compostos por questões e respostas previamente definidas, estratégia amplamente adotada para mensuração de ganhos em arquiteturas de raciocínio e orquestração de LLMs, e usada em trabalhos como *ReAct* [5] e *Beyond the Strongest LLM* [12]. Os experimentos são conduzidos com diferentes modelos da família Llama 3.1, com diferentes quantidades de parâmetros utilizados na execução do modelo, representando distintos níveis de complexidade computacional, e avaliados por meio dos *benchmarks* MMLU [13] e GPQA [14], sendo a acurácia, medida pela quantidade de acertos entre a alternativa selecionada pelo sistema de LLM e o gabarito oficial.

## II. Conceitos

Esta seção apresenta os conceitos fundamentais necessários para a compreensão do trabalho proposto. São definidos os termos técnicos centrais utilizados ao longo do texto, descritas as principais estratégias de raciocínio e refinamento aplicadas a modelos de linguagem, e introduzido o paradigma de orquestração adotado neste trabalho.

### A. Modelos de Linguagem e a Arquitetura de Harness

Embora os *Large Language Models* (LLMs) [15] sejam amplamente consolidados como geradores probabilísticos de *tokens* baseados na arquitetura *Transformer* [16], a evolução recente na aplicação dessas tecnologias migrou de chamadas diretas e lineares para o uso de estruturas de orquestração mais robustas. Um detalhamento teórico e histórico aprofundado sobre o funcionamento desses modelos de linguagem pode ser encontrado no levantamento conduzido por Zhao et al. [17].

Na prática, a organização dessas interações é viabilizada por meio de um *harness*, termo que se refere à estrutura lógica e às regras de orquestração que envolvem um modelo de linguagem para guiar seu processo de inferência, funcionando como uma camada de coordenação entre o *prompt* inicial do usuário e a saída do modelo [12], [18]. Um *harness* pode incluir etapas de planejamento, decomposição de tarefas, validação intermediária e composição de respostas finais. Variações na arquitetura do *harness* podem causar impactos significativos no desempenho do sistema como um todo, mesmo quando o modelo base permanece o

mesmo.

Esse conceito está diretamente relacionado à noção de *Sistemas Compostos de IA*, definida por Zaharia et al. [18] como arquiteturas que resolvem tarefas de inteligência artificial por meio de múltiplos componentes que interagem entre si, incluindo chamadas a modelos, recuperadores de informação e ferramentas externas. Segundo essa perspectiva, os ganhos mais significativos em aplicações de IA contemporâneas passaram a depender da engenharia de sistemas que combinam componentes especializados em fluxos coordenados, em vez de se apoiarem unicamente no aumento de escala dos modelos base [18].

Essa tendência se manifesta em ferramentas industriais que utilizam LLMs integrados a *harnesses* especializados para tarefas de engenharia e automação. Exemplos incluem o Claude Code [19], interface de linha de comando voltada ao desenvolvimento assistido por IA; o GPT Codex [20], otimizado para geração e compreensão de código; e o OpenCLI [21], voltado à automação de comandos de terminal. Essas ferramentas demonstram como a combinação de planejamento, decomposição de tarefas e validação iterativa expande a capacidade computacional útil dos modelos base.

### B. Estratégias de Raciocínio e Refinamento

A literatura demonstra que a qualidade da inferência de um LLM pode ser melhorada de forma significativa quando o processo é estruturado em fases [2], [3]. O método *Chain-of-Thought* [2] e sua generalização *Tree of Thoughts* [3] mostraram a importância de induzir o modelo a explicitar passos intermediários de raciocínio. Abordagens como *ReAct* [5] ampliaram esse princípio ao combinar o raciocínio interno do modelo com a capacidade de invocar ferramentas externas, permitindo corrigir alucinações por meio de observações diretas do ambiente.

De forma complementar, pipelines baseados em ciclos de *feedback* iterativo também apresentam ganhos consistentes. O framework *Reflexion* [6] introduziu ciclos nos quais o modelo atua como seu próprio crítico, revisando saídas com base em reforço verbal externo. A abordagem de *Self-Debugging* [7] demonstrou que LLMs podem identificar e corrigir seus próprios erros quando guiados de forma sistemática. Na mesma direção, o método *Self-Refine* [8] consolidou a eficácia do refinamento iterativo ao demonstrar que modelos podem gerar *feedback* crítico sobre suas próprias respostas e utilizá-lo para melhorar as saídas de forma sucessiva, contornando limitações da geração em uma única etapa. Essa capacidade de autocrítica e revisão contínua constitui uma premissa fundamental para a proposta deste trabalho.

Além dessas abordagens, métodos focados na decomposição de tarefas complexas também contribuem para a redução de erros lógicos e omissões. Técnicas de *prompting* baseadas em decomposição, como *Least-to-Most* [4], *Decomposed Prompting* [22] e *Plan-and-Solve* [23], sustentam que separar o planejamento da execução e dividir problemas em subproblemas menores melhora o desempenho do modelo, especialmente quando combinado com mecanismos de validação intermediária.

### C. Degradação de Contexto

Embora as técnicas apresentadas nas subseções anteriores tenham demonstrado eficácia individual, muitas delas dependem do acúmulo contínuo de estado em uma única janela de contexto, o que pode agravar problemas de degradação à medida que o histórico cresce. Liu et al. [9] demonstraram empiricamente que LLMs apresentam perda significativa de desempenho quando precisam recuperar informações relevantes posicionadas no meio de sequências longas, fenômeno descrito como “perdidos no meio” (*lost in the middle*).

Na prática, esse comportamento se manifesta de diversas formas: compressão implícita de informações, perda de relevância contextual, aumento de inconsistências e maior incidência de alucinações em execuções prolongadas [9], [17]. A literatura contemporânea frequentemente associa esse conjunto de efeitos ao conceito de *context rot*, referindo-se à degradação progressiva da qualidade das respostas conforme o contexto acumula ruído, redundâncias e informações que competem pela atenção do modelo [9].

### D. O Ralph Wiggum Loop

Diante dos problemas de degradação de contexto, o Ralph Wiggum Loop [11] surgiu na comunidade de engenharia de software como um paradigma de orquestração que aborda diretamente essa limitação. Popularizado por Geoffrey Huntley, o paradigma se baseia em dois pilares centrais: (i) a decomposição do problema em tarefas independentes e atômicas, e (ii) a execução iterativa de cada tarefa até que critérios de aceite previamente definidos sejam satisfeitos. Um aspecto central dessa abordagem é o princípio de *Fresh Context* [11]: o contexto é reinicializado a cada iteração, e apenas os resultados intermediários essenciais são preservados em arquivos estruturados. Essa estratégia elimina o acúmulo de histórico que caracteriza as arquiteturas tradicionais de agentes, mitigando ativamente a degradação de contexto [11], [24].

Em sua formulação original, o Ralph Wiggum Loop foi concebido especificamente para fluxos de engenharia de software, com etapas voltadas à definição de funcionalidades, requisitos, critérios de aceite e integração com sistemas de versionamento como Git. Ainda assim, seus princípios de execução *stateless* e validação iterativa apresentam relevância direta para os problemas discutidos na literatura de LLMs.

A validação acadêmica dessa abordagem foi reforçada pelo estudo de McComb et al. [24], que avaliou o impacto de agentes baseados no Ralph Wiggum Loop na resolução de problemas complexos de design de engenharia. Além de comprovar a eficácia da abordagem *stateless*, o estudo propôs aprimoramentos por meio de ciclos metacognitivos de co-regulação, nos quais um agente avaliador atua criticando ativamente os resultados para mitigar vieses e fixações de paradigma. Este trabalho se apoia em fundamentos semelhantes para justificar o uso do paradigma *stateless*, porém adaptando a orquestração para a resolução de questões de propósito geral em múltiplos domínios do conhecimento.




Figura 1. Fluxo macro do pipeline de *thinking*.

### III. Metodologia

#### A. Análise macro do processo de *thinking*

O diagrama a seguir apresenta o fluxo macro do pipeline de *thinking* proposto neste trabalho, oferecendo uma visão consolidada de todas as fases que o compõem.

O pipeline inicia-se a partir de um *prompt* de entrada fornecido pelo usuário e segue etapas organizadas em loops aninhados: (i) definição dos critérios de aceitação e do formato de saída; (ii) decomposição do problema em tarefas atômicas independentes; (iii) processamento das tarefas no **Micro Loop**, onde cada sub tarefa é resolvida individualmente até sua conclusão; (iv) compilação dos resultados para avaliação no **Macro Loop** em relação aos critérios globais. Se a avaliação identificar lacunas, o pipeline cria tarefas complementares e reinicia o Micro Loop até que todos os critérios sejam satisfeitos. Esse encadeamento estruturado favorece convergência iterativa e consistência lógica na geração da resposta final.

Um aspecto central da arquitetura é a separação deliberada entre as fases de execução: cada etapa opera de forma *stateless* em relação às demais, sem carregar diretamente o

histórico de raciocínio das fases anteriores. Em vez disso, o sistema preserva apenas artefatos estruturados, como os arquivos `planning.json` e `tasks_results.json`, que atuam como memória persistente e controlada entre as etapas. Essa escolha visa mitigar o contexto degradado (*context rot*) e garantir que cada chamada ao LLM opere com o menor contexto necessário, reduzindo o risco de contaminação por raciocínios prévios.

#### B. Análise micro das fases

A seguir, cada fase do pipeline é detalhada individualmente. Para cada fase, são descritos: os agentes de LLM envolvidos, os dados de entrada e saída, e o fluxo de controle interno. Essa granularidade tem o objetivo de tornar o processo inteiramente replicável por pesquisadores externos.


##### B.1 Agentes de LLM

Neste trabalho, adota-se uma definição restrita de *agente*: trata-se de um componente composto exclusivamente por um *prompt* pré-definido e uma chamada ao modelo de linguagem (LLM\_CALL). Diferentemente de arquiteturas que atribuem a agentes acesso a ferramentas externas, chamadas a APIs, servidores MCP ou capacidades de navegação, os agentes aqui descritos operam de forma isolada, recebendo um contexto de entrada estruturado, processando via LLM e retornando uma saída textual ou estruturada em JSON. Essa restrição é intencional: ao eliminar dependências externas, torna-se possível avaliar de forma mais direta o impacto da orquestração e do *prompting* sobre a qualidade das respostas, isolando as variáveis de interesse do estudo.

Todos os *prompts* de agentes são redigidos em inglês. Estudos como os de Huang et al. [huang2024beyond](#) e Shi et al. [25] mostram que modelos de linguagem multilíngues tendem a produzir resultados de maior qualidade quando instruídos no idioma em que foram mais amplamente treinados, predominantemente o inglês, independentemente do idioma da questão de entrada. O trabalho de Qin et al. [qin2023crosslingual](#) reforça esse achado ao demonstrar que a combinação de *prompting* em inglês com raciocínio *zero-shot* em cadeia produz ganhos consistentes mesmo em línguas de menor representação nos dados de treinamento. A adoção do inglês como idioma padrão dos *prompts* de agentes visa, portanto, maximizar a qualidade do raciocínio interno do modelo, sem prejuízo ao idioma da resposta entregue ao usuário, que é determinado separadamente, conforme descrito na seção seguinte.

Adicionalmente, todos os *prompts* são construídos utilizando a sintaxe *Markdown*, com delimitadores explícitos de seção para separar instruções gerais, contexto de entrada e especificações de saída. Estudos como os de He et al. [he2024promptformatting](#) e Liu et al. [26] mostram que a formatação do *prompt* afeta de forma mensurável o desempenho dos modelos, e que otimizações conjuntas de conteúdo e formato produzem ganhos adicionais sobre a otimização exclusiva do conteúdo textual. A adoção de *Markdown* visa, portanto, tornar delimitadores, hierarquias






**Figura 2.** Fase de definição dos critérios de aceite da resposta final.

e restrições mais salientes durante a inferência, contribuindo para respostas mais consistentes com as instruções fornecidas.

## B.2 Definição dos critérios de aceite da resposta final

Esta fase é responsável por transformar o *prompt* bruto do usuário em dois artefatos que guiarão todo o processo posterior: (i) uma lista de critérios de aceitação que a resposta final deverá satisfazer, e (ii) uma especificação do formato de saída esperado. Para isso, dois agentes são acionados em sequência a partir da mesma entrada.

O `acceptance_criteria_agent` recebe o *prompt* de entrada do usuário e é responsável por identificar e listar, de forma explícita, os critérios objetivos e verificáveis que uma resposta satisfatória deve cumprir. Em seguida, o `expected_output_format_agent` analisa o mesmo *prompt*, buscando por indicações explícitas de formato de saída, como “retorne somente a alternativa correta”, “responda em JSON” ou “elabore uma justificativa”. Caso nenhuma indicação seja encontrada, o agente infere o formato mais adequado ao tipo de tarefa: para questões de múltipla escolha, o padrão é “retornar somente a letra da alternativa correta, sem explicações adicionais”; para questões abertas, “texto corrido em formato Markdown”. O idioma da resposta final é tratado como parte integrante do formato de saída: se o usuário o especificou explicitamente, essa instrução é acatada; caso contrário, o agente infere o idioma a partir do idioma utilizado na entrada e o registra como especificação. Quando exemplos de saída são fornecidos pelo usuário, estes são incorporados ao campo



**Figura 3.** Fase de quebra de tarefas independentes.

correspondente.

Os resultados dessas duas chamadas são então consolidados em um arquivo JSON denominado `planning.json`, que servirá de artefato central de memória estruturada para todas as fases subsequentes. A estrutura do `planning.json` é inspirada no `prd.json` do Ralph Wiggum Loop original, porém estendida para incorporar as informações de critérios de aceitação e formato de saída.

```

{
  "general_infos": {
    "acceptance_criteria": [],
    "expected_output_format": {
      "format": "",
      "response_language": ""
    }
  },
  "tasks": []
}
  
```

O campo `tasks` é inicialmente vazio e será preenchido pela fase seguinte. A separação entre `general_infos` e `tasks` é proposital: as informações gerais são invariantes ao longo de todo o pipeline, enquanto as tarefas podem ser adicionadas iterativamente por planos complementares.

## B.3 Quebra de Tasks Independentes

Esta fase é, em termos de responsabilidade lógica, a mais crítica de todo o pipeline: é aqui que se implementa o princípio central do Ralph Wiggum Loop, a decomposição do problema em unidades mínimas e independentes de execução. O agente `atomic_tasks_planner_agent` recebe como entrada o *prompt* do usuário e o campo `general_infos` do `planning.json` gerado na fase anterior, e a partir disso constrói um plano de tarefas atômicas.

O conceito de atomicidade empregado é preciso: uma tarefa é considerada atômica quando representa a menor unidade de trabalho possível e pode ser executada e avaliada de forma completamente independente das demais tarefas do plano, sem necessidade de acessar ou reutilizar os resultados de outras tarefas durante sua própria execução. Essa propriedade é fundamental para garantir o funcionamento correto do mecanismo de *fresh context*, pois, se tarefas dependessem umas das outras durante a execução, seria necessário carregar contexto acumulado, o que reintroduziria os problemas de degradação que a arquitetura busca mitigar.

Após a geração do plano inicial, o agente `atomic_tasks_revisor_agent` é acionado para verificar se todas as tarefas propostas satisfazem o critério de independência, retornando um JSON com um campo booleano de aprovação e uma justificativa. Se problemas forem identificados, o agente `atomic_tasks_rewriter_agent`, que incorpora em seu *prompt* todas as regras e restrições do planejador, é acionado para reescrever o plano com base na justificativa fornecida. Esse ciclo de revisão repete-se até que o revisor valide o plano, garantindo que apenas tarefas verdadeiramente independentes avancem para a fase de execução.

Cada tarefa do plano é representada no `planning.json` no seguinte formato:


```
{
  "id": "",
  "title": "",
  "description": "",
  "acceptance_criteria": [],
  "pass_phase": false
}
```

O campo `pass_phase` é inicializado como `false` para todas as tarefas e atualizado para `true` ao final da execução bem-sucedida de cada uma, funcionando como marcador de progresso para o mecanismo iterativo.

#### B.4 Resolução das tarefas — Ralph Loop

Esta fase implementa o núcleo iterativo do Ralph Wiggum Loop adaptado ao contexto deste trabalho. O processo inicia pela verificação do `planning.json`: enquanto existirem tarefas com `pass_phase: false`, o pipeline seleciona a próxima tarefa pendente e inicia um ciclo de tentativa, avaliação e revisão.

Cada iteração do ciclo consiste em: (i) uma chamada ao LLM contendo exclusivamente o conteúdo da tarefa atual, sem histórico acumulado de outras tarefas, seguida de (ii) uma chamada ao agente `task_outcome_reviewer_agent`, que compara a resposta gerada com os `acceptance_criteria` da tarefa. O revisor retorna um JSON com um campo booleano de aprovação e uma justificativa. Se o revisor aprovar a resposta, ela é salva no arquivo `tasks_results.json` e o campo `pass_phase` da tarefa é atualizado para `true`. Se reprovar, a justificativa é incorporada à próxima chamada




**Figura 4.** Fase de resolução iterativa das tarefas (Ralph Loop).

ao LLM, configurando um ciclo de refinamento guiado, análogo aos mecanismos de *Reflexion* [6] e *Self-Debugging* [7].

No que diz respeito à persistência dos resultados, adota-se uma adaptação do princípio original do Ralph Wiggum Loop, que estabelece que “All memory lives in files and git, not the model”. Como o presente trabalho aplica o pipeline a cenários distintos do desenvolvimento de software, o mecanismo de *commit* em repositório Git é substituído pelo arquivo `tasks_results.json`, que acumula exclusivamente as respostas finais aprovadas de cada tarefa, sem registrar histórico de raciocínio, tentativas anteriores ou qualquer metadado do ciclo iterativo.

Para mitigar o risco de *deadlock*, implementa-se um mecanismo de controle denominado *pânico*. Um contador `task_interactions` é incrementado a cada chamada ao LLM dentro do ciclo de uma tarefa. Quando esse contador atinge o valor de `max_iterations`, a fase encerra automaticamente e a resposta disponível no momento é salva no `tasks_results.json`, mesmo que os critérios não tenham sido plenamente atendidos.



**Figura 5.** Fluxograma de avaliação dos critérios de aceitação da resposta final.

### B.5 Avaliação dos critérios de aceitação


Ao término da resolução de todas as tarefas do plano, o pipeline consolida os resultados armazenados no `tasks_results.json` e os submete a uma avaliação global frente aos critérios de aceitação definidos em `general_infos.acceptance_criteria` do `planning.json`. Essa fase é executada pelo agente `final_response_acceptance_criteria_reviewer_agent`, que recebe ambos os artefatos como entrada.

A lógica é análoga à dos revisores de tarefa individual, porém operando em um nível de abstração superior: em vez de avaliar uma resposta pontual contra critérios locais de uma tarefa, o agente avalia se o conjunto total de resultados gerados fornece insumos suficientes para construir uma resposta final que atenda a todos os critérios globais. Dois fluxos de saída são possíveis a partir dessa avaliação: caso todos os critérios sejam considerados atendidos, o pipeline avança para a criação da resposta final; caso contrário, avança para a criação de um plano adicional complementar.

### B.6 Criação de plano complementar

Quando a avaliação global indica que os critérios de aceitação não foram plenamente atendidos, o pipeline não retorna ao início, o que implicaria descartar e reprocessar etapas já concluídas. Em vez disso, adota-se uma estratégia de afunilamento progressivo: o agente `acceptance_gap_prompt_creator` analisa a justificativa retornada pelo revisor global e produz um novo *prompt* no estilo de entrada de usuário, descrevendo exclusivamente o que ainda precisa ser resolvido para cobrir as lacunas identificadas.

Esse *prompt* é então submetido ao `atomic_tasks_planner_agent`, o mesmo agente da fase de quebra de tarefas independentes, que gera um novo conjunto de tarefas complementares. Essas novas tarefas são concatenadas ao campo `tasks` do `planning.json` original, e o pipeline retorna à fase de resolução das tarefas para executá-las.



**Figura 6.** Criação de plano complementar para critérios não atendidos.

Esse mecanismo constitui, na prática, um segundo nível de loop que garante a convergência iterativa do pipeline: a cada ciclo, o conteúdo gerado aproxima-se do que é necessário para satisfazer todos os critérios de aceitação, sem desperdiçar o trabalho já realizado nas iterações anteriores.

### B.7 Criação da resposta final

A fase de criação da resposta final assume que o `tasks_results.json` contém todos os insumos necessários para compor uma resposta que satisfaça integralmente os critérios de aceitação globais, premissa garantida pela fase de avaliação anterior. É nesta fase, e somente nesta, que o conteúdo do `tasks_results.json` é efetivamente recuperado e utilizado.

O agente `final_response_composer_agent` recebe como entrada o arquivo completo de resultados, o campo `general_infos.expected_output_format` do `planning.json` e o *prompt* original do usuário, utilizando-os em conjunto para compor a resposta final no formato e idioma especificados. O retorno desse agente é a saída direta do pipeline ao usuário, encerrando o processo de *thinking*.

## IV. Cronograma do projeto

## V. Referências

### Referências

- [1] Y. Lee, R. Nair, Q. Zhang, K. Lee, O. Khattab e C. Finn, "Meta-Harness: End-to-End Optimization of Model Harnesses," *arXiv preprint arXiv:2603.28052*, 2026.
- [2] J. Wei et al., "Chain-of-Thought Prompting Elicits Reasoning in Large Language Models," *arXiv preprint arXiv:2201.11903*, 2022.

**Tabela I.** Cronograma das atividades do projeto.

| Atividade                                       | fev | mar | abr | mai | jun | jul | ago | set | out | nov |
|-------------------------------------------------|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|
| Revisão bibliográfica e refinamento da proposta | X   | X   | X   | X   |     |     |     |     |     |     |
| Definição da arquitetura                        |     | X   | X   | X   | X   |     |     |     |     |     |
| Desenvolvimento do Paper                        |     | X   | X   | X   | X   | X   | X   | X   | X   | X   |
| Implementação prática do código                 |     |     |     | X   | X   | X   | X   | X   | X   |     |
| Análise final                                   |     |     |     |     |     |     |     |     | X   | X   |

- [3] S. Yao et al., “Tree of Thoughts: Deliberate Problem Solving with Large Language Models,” *arXiv preprint arXiv:2305.10601*, 2023.
- [4] D. Zhou et al., “Least-to-most prompting enables complex reasoning in large language models,” *arXiv preprint arXiv:2205.10625*, 2022.
- [5] S. Yao et al., “ReAct: Synergizing Reasoning and Acting in Language Models,” *arXiv preprint arXiv:2210.03629*, 2022.
- [6] N. Shinn, F. Cassano, B. Labash, A. Gopinath, K. Narasimhan e S. Yao, “Reflexion: Language Agents with Verbal Reinforcement Learning,” *arXiv preprint arXiv:2303.11366*, 2023.
- [7] X. Chen, M. Lin, N. Schärli e D. Zhou, “Teaching Large Language Models to Self-Debug,” *arXiv preprint arXiv:2304.05128*, 2023.
- [8] A. Madaan et al., “Self-Refine: Iterative Refinement with Self-Feedback,” *arXiv preprint arXiv:2303.17651*, 2023.
- [9] N. F. Liu et al., “Lost in the Middle: How Language Models Use Long Contexts,” *Transactions of the Association for Computational Linguistics*, v. 12, pp. 277–294, 2024.
- [10] K. Hong, A. Troynikov e J. Huber, “Context Rot: How Increasing Input Tokens Impacts LLM Performance,” Chroma, rel. técn., jul. de 2025. endereço: <https://trychroma.com/research/context-rot>
- [11] G. Ghuntley, *Ralph Loop: A Structured Orchestration Pattern for LLM Inference*, Online. Disponível em: <https://ghuntley.com/specs/ralph/>, Acesso em: abr. 2026, 2025.
- [12] Z. Wang et al., “Beyond the Strongest LLM: Multi-Turn Multi-Agent Orchestration vs. Single LLMs on Benchmarks,” *arXiv preprint arXiv:2509.23537*, 2025.
- [13] D. Hendrycks et al., “Measuring Massive Multitask Language Understanding,” em *International Conference on Learning Representations*, 2021.
- [14] D. Rein et al., “GPQA: A Graduate-Level Google-Proof Q&A Benchmark,” *arXiv preprint arXiv:2311.12022*, 2023.
- [15] T. B. Brown et al., “Language Models are Few-Shot Learners,” em *Advances in Neural Information Processing Systems*, 2020.
- [16] A. Vaswani et al., “Attention is All You Need,” em *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [17] W. X. Zhao et al., “A Survey of Large Language Models,” *arXiv preprint arXiv:2303.18223*, 2023.
- [18] M. Zaharia et al., *The Shift from Models to Compound AI Systems*, Berkeley Artificial Intelligence Research Blog. Disponível em: <https://bair.berkeley.edu/blog/2024/02/18/compound-ai-systems/>, Acesso em: mai. 2026, 2024.
- [19] Anthropic, *Claude Code*, <https://www.anthropic.com/claude-code>, 2026.
- [20] M. Chen et al., “Evaluating Large Language Models Trained on Code,” *arXiv preprint arXiv:2107.03374*, 2021.
- [21] *OpenCLI*, <https://opencli.ai/>, 2026.
- [22] T. Khot et al., “Decomposed prompting: A modular approach for solving complex tasks,” *arXiv preprint arXiv:2210.02406*, 2022.
- [23] L. Wang et al., “Plan-and-solve prompting: Improving zero-shot chain-of-thought reasoning by large language models,” *arXiv preprint arXiv:2305.04091*, 2023.
- [24] C. McComb et al., “Supervising Ralph Wiggum: Exploring a Metacognitive Co-Regulation Agentic AI Loop for Engineering Design,” *arXiv preprint arXiv:2603.24768*, 2026.
- [25] F. Shi, M. Suzgun, M. Freitag, X. Wang, M. Surdeanu e J. Wei, “Language Models are Multilingual Chain-of-Thought Reasoners,” em *International Conference on Learning Representations*, 2023.
- [26] Y. Liu et al., “Beyond Prompt Content: Enhancing LLM Performance via Content-Format Integrated Prompt Optimization,” *arXiv preprint arXiv:2502.04295*, 2025.