

# Sistemas Compostos de IA: Otimização de Respostas em Benchmarks Objetivos por meio de Orquestração Baseada no Ralph Loop

**Hugo Emílio Nomura, Pedro Henrique Correia de Oliveira, Pedro Henrique Satoru Lima Takahashi, Vitor Monteiro Vianna**

Ciência da Computação – Centro Universitário FEI, campus São Paulo

unifhnomura@fei.edu.br, unifpoliveira@fei.edu.br, unifptakahashi@fei.edu.br, unievvianna@fei.edu.br

**Orientador: Charles Henrique Porto Ferreira**

Departamento de Ciência da Computação, Centro Universitário FEI

cferreira@fei.edu.br

**Resumo:** Os *Large Language Models (LLMs)* evoluíram de simples geradores de texto para sistemas capazes de executar etapas internas de raciocínio prolongado antes de produzir uma resposta. Implementações modernas, como o *Claude Opus 4.6* e o *GPT-5.5*, passaram a incorporar mecanismos de *planning*, *refinement* e *reasoning* iterativo como estratégia para aumentar a qualidade, coerência e capacidade analítica das respostas geradas. Ao mesmo tempo em que esses mecanismos podem melhorar significativamente a qualidade das respostas, eles também introduzem desafios relacionados ao crescimento contínuo da janela de contexto durante o processo de raciocínio, podendo levar ao fenômeno conhecido como *context rot* — a degradação progressiva da qualidade das respostas à medida que o contexto acumula ruídos, redundâncias e contradições, aumentando o risco de alucinações e omissões lógicas. Nesse cenário, este estudo investiga o quanto é possível melhorar a qualidade das respostas de um *LLM* exclusivamente por meio de chamadas iterativas ao próprio modelo, sem o uso de ferramentas externas como acesso ao terminal ou *MPCs*. Para analisar os ganhos proporcionados por fluxos estruturados de raciocínio e, ao mesmo tempo, mitigar problemas de *context rot*, foi implementada uma adaptação do *Ralph Wiggum Loop* — originalmente concebido para tarefas de desenvolvimento de software — para o domínio de questões de múltipla escolha. A arquitetura proposta mantém o princípio *stateless* entre fases, no qual cada etapa opera sem herdar o contexto acumulado das anteriores, preservando apenas o contexto necessário para concluir sua própria tarefa. Dessa forma, torna-se possível medir, rastrear e comparar empiricamente o impacto do processo na performance do modelo. Para validar a abordagem, são utilizadas as bases *MMLU* e *GPQA* — conjuntos de questões de múltipla escolha que abrangem áreas como matemática, lógica, história e ciências, em níveis que vão do básico ao doutorado —, comparando a acurácia obtida por chamadas diretas ao modelo com aquela alcançada pelo *Harness* estruturado.

**Palavras-chaves:** *Large Language Models (LLMs)*. *Ralph Wiggum Loop*. Sistemas Compostos de IA. Engenharia de Prompt. Decaimento de Contexto (*Context Rot*).

## I. Introdução

Os modelos de linguagem de grande porte (*Large Language Models — LLMs*) [1] deixaram de ser apenas geradores de texto e passaram a funcionar como plataformas compostas por diferentes camadas de processamento, coordenação e abstração. Essa evolução permitiu capacidades como raciocínio em múltiplas etapas, planejamento intermediário e orquestração de subagentes, mas também tornou evidente que boa parte da melhoria observada nas respostas não vem apenas do modelo base, e sim das arquiteturas e *pipelines* que organizam o processo de inferência.

Este trabalho parte de dois problemas centrais observados tanto na prática quanto na literatura: (1) a diferença frequente entre respostas iniciais e respostas revisadas produzidas por um mesmo modelo — algo comum em interações com modelos mais antigos, especialmente durante a popularização do *GPT-3.5*, quando perguntas como "Tem certeza?", "revise sua resposta" ou até mesmo o apontamento direto de erro ("você errou") frequentemente levavam o modelo a corrigir sua própria saída —, e (2) a forma como fluxos de raciocínio (*prompting* encadeado, agentes e

*pipelines*) são implementados atualmente, incluindo suas limitações relacionadas ao crescimento do contexto.

O primeiro problema surge porque, em tarefas não triviais, a primeira resposta gerada pelo modelo costuma ser apenas uma tentativa inicial, sujeita a erros, omissões e inconsistências. Diversos trabalhos mostram que essa limitação pode ser reduzida quando a inferência é dividida em etapas menores, com validações e *feedback* intermediário. *Chain-of-Thought* [2] e *Tree of Thoughts* [3], por exemplo, mostram ganhos ao incentivar o modelo a gerar e avaliar passos intermediários de raciocínio; *ReAct* [4] demonstra benefícios ao alternar raciocínio com ações e observações; enquanto abordagens iterativas, como *Reflexion* [5] (reflexão após avaliação externa), *Self-Debugging* [6] (correção guiada por testes) e *Self-Refine* [7] (refinamento iterativo baseado em *feedback* gerado pelo próprio modelo), indicam que ciclos de tentativa, avaliação e revisão podem aumentar significativamente a taxa de acerto. Em paralelo, métodos de decomposição e planejamento — como *Least-to-Most Prompting* [8], *Decomposed Prompting* [9] e *Plan-and-Solve Prompting* [10] — reforçam empiricamente

que dividir problemas complexos em subtarefas, separar planejamento de execução e limitar o escopo contextual de cada etapa reduz erros lógicos e omissões, especialmente quando existe algum mecanismo de verificação automática. Assim, a melhora observada não depende apenas de gerar mais *tokens* ou realizar chamadas mais longas, mas da forma como o *pipeline* controla o contexto, organiza o planejamento e valida as respostas intermediárias.

O segundo problema está relacionado às práticas atuais de *thinking* em LLMs e às limitações de janelas de contexto extensas. Em arquiteturas populares de agentes, como *ReAct* [4], já citado anteriormente, o modelo normalmente opera acumulando em uma única janela um histórico crescente de raciocínios, ações e observações. Embora isso facilite o encadeamento do processo, também aumenta o risco de degradação conforme o contexto cresce. Esse comportamento é consistente com evidências empíricas sobre contextos longos: no trabalho *Lost in the Middle* [11], por exemplo, observa-se perda de desempenho quando o modelo precisa recuperar informações relevantes em sequências extensas, principalmente quando essas informações ficam "perdidas" no meio do contexto. Na prática, a comunidade costuma descrever esse acúmulo progressivo usando termos como "esgotamento de contexto", "compactação" e *context rot*: conforme o histórico aumenta, partes importantes do conteúdo perdem relevância relativa, competem com ruído e podem ser diluídas por resumos implícitos, levando a omissões, inconsistências e aumento de alucinações.

Diante dessas propostas, adotamos como referência prática o *Ralph Wiggum Loop* [12], popularizado por Geoffrey Huntley no contexto de desenvolvimento de software. Nesse modelo, um agente executa tarefas seguindo um ciclo rígido de geração, validação e repetição, buscando produzir artefatos corretos sob critérios objetivos de aceite. O objetivo deste trabalho é adaptar essa arquitetura — originalmente voltada para engenharia de software — para investigar se os mesmos princípios podem melhorar a resolução de questões objetivas em benchmarks de múltipla escolha. Em termos gerais, o *Ralph Wiggum Loop* pode ser entendido como um *pipeline* baseado em dois pilares principais: (i) a decomposição do objetivo em fases menores e isoladas e (ii) a execução iterativa de cada fase até que critérios de aceite previamente definidos sejam satisfeitos. Assim, cada etapa é executada de maneira *stateless*, sem carregar diretamente todo o histórico da fase anterior; em vez disso, o sistema preserva apenas artefatos controlados, como instruções, respostas intermediárias ou resultados de validação, reiniciando o contexto a cada nova iteração (*Fresh Context*). Além disso, cada fase passa por um ciclo contínuo de tentativa e validação: a resposta produzida pelo modelo é avaliada contra critérios específicos e, caso não seja considerada satisfatória, a própria fase é executada novamente até atingir o resultado esperado antes de avançar para a próxima etapa. Embora o nome e o formato operacional sejam recentes, a lógica do loop se conecta diretamente a linhas acadêmicas já discutidas — decomposição (*Least-to-Most* [8]; *Decomposed Prompting* [9]), separação entre planejamento e execução (*Plan-and-Solve* [10]) e

ciclos de reflexão e autodepuração iterativa (*Reflexion* [5]; *Self-Debugging* [6]; *Self-Refine* [7]) — oferecendo uma forma pragmática de aplicar esses conceitos em *pipelines* reproduzíveis.

Neste trabalho, adotamos a hipótese de que a qualidade objetiva das respostas em tarefas de múltipla escolha depende não apenas do LLM utilizado, mas também do *Harness* que governa sua execução — isto é, do conjunto de estratégias de decomposição, validação e orquestração de chamadas aplicadas entre o *prompt* inicial e a resposta final, sem uso de ferramentas externas. Para testar essa hipótese, buscamos medir o quanto esse *Harness* melhora os resultados em comparação com chamadas simples ao modelo, utilizando três modelos distintos (*Llama 3.1 8B*, *Llama 3.1 70B*, *Llama 3.1 405B*) escolhidos para representar diferentes níveis de complexidade, desde modelos menores até incluir ao menos um modelo moderno. Para cada modelo, comparamos duas configurações: (i) uma inferência linear, realizada por meio de uma única chamada direta ao modelo, e (ii) a mesma inferência mediada pelo nosso *Harness* — um *pipeline* estruturado inspirado no *Ralph Wiggum Loop*, contendo fases de planejamento, execução e validação realizadas exclusivamente por chamadas iterativas ao próprio modelo. A avaliação de desempenho é realizada por meio de *benchmarks* construídos sobre as bases *GPQA* e *MLLU*, compostas por questões de múltipla escolha com alternativas e gabaritos conhecidos; nesses conjuntos, a métrica principal utilizada é a acurácia obtida pela correspondência entre a alternativa selecionada pelo sistema e o gabarito oficial.

## II. Trabalhos Relacionados

O desenvolvimento de arquiteturas e técnicas de *harness* para potencializar o raciocínio de LLMs tem sido um campo ativo de pesquisa, subdividindo-se em estratégias de *prompting* estendido e fluxos de trabalho baseados em agentes.

### A. Estratégias de Raciocínio e Agentes

A literatura demonstra amplamente que a inferência primária de um modelo pode ser significativamente aprimorada quando estruturada em fases. O método *Chain-of-Thought* [2] e sua generalização *Tree of Thoughts* [3] evidenciaram a importância de induzir o modelo a explicitar passos intermediários. Abordagens como *ReAct* [4] deram um passo além ao sinergizar o raciocínio interno com a capacidade de invocar ferramentas externas (*Acting*), permitindo contornar alucinações por meio de observações diretas do ambiente.

Paralelamente, *pipelines* interativos baseados em *feedback* demonstram alta eficácia. *Reflexion* [5] implementou ciclos em que o modelo atua como seu próprio crítico, revisando saídas com base em reforço verbal externo, e o *Self-Debugging* [6] mostrou que os LLMs podem depurar seus próprios erros quando guiados de forma sistemática. Na mesma linha, a abordagem *Self-Refine* [7] consolidou a eficácia do refinamento iterativo ao demonstrar que os modelos podem gerar *feedback* crítico sobre as próprias

respostas e utilizá-lo para refinar as saídas sucessivamente, contornando limitações de geração *one-shot*. Essa capacidade de autocrítica e revisão contínua constitui uma premissa fundamental para a nossa proposta, que expande esse conceito integrando-o ao paradigma *stateless* do *Ralph Loop*. Adicionalmente, métodos focados na redução da sobrecarga cognitiva através da divisão de tarefas complexas — como *Least-to-Most* [8], *Decomposed Prompting* [9] e *Plan-and-Solve* [10] — sustentam a premissa de que separar planejamento e execução mitiga falhas lógicas e omissões.

### B. Orquestração Estruturada e o Ralph Wiggum Loop

Embora as técnicas supracitadas representem a base teórica de agentes autônomos, muitas dependem do acúmulo contínuo de estado em uma única janela de contexto, fenômeno que agrava a degradação e o esquecimento descritos no trabalho *Lost in the Middle* [11]. Frente a esse problema, o *Ralph Wiggum Loop* [12] emergiu na comunidade de engenharia de software como um paradigma pragmático alternativo. A técnica isola a execução em etapas rigidamente separadas e reinicializa o contexto a cada iteração (*Fresh Context*), armazenando estritamente os resultados intermediários essenciais.

A validação acadêmica rigorosa de uma estrutura semelhante a esta foi recentemente evidenciada pelo estudo *Supervising Ralph Wiggum: Exploring a Metacognitive Co-Regulation Agentic AI Loop for Engineering Design* [13], que avaliou o impacto de agentes baseados no *Ralph Wiggum Loop* para a resolução de problemas complexos de design de pacotes de baterias na engenharia. O estudo comprovou não apenas a eficácia da abordagem *stateless*, mas propôs aprimoramentos através de ciclos metacognitivos de co-regulação (CRDAL), nos quais um agente avaliador atua criticando ativamente o design a fim de mitigar vieses e fixações de paradigma.

Este trabalho apoia-se em fundamentações similares para justificar o uso do paradigma de execução *stateless* em nossa orquestração. Contudo, enquanto o estudo *Supervising Ralph Wiggum: Exploring a Metacognitive Co-Regulation Agentic AI Loop for Engineering Design* [13] concentrou a arquitetura na otimização de métricas tangíveis de engenharia e modelagem paramétrica, nossa metodologia isola e adapta os ganhos da orquestração estrita do *Ralph Loop* para elevar a capacidade de resolução de questões de propósito geral em múltiplos domínios do conhecimento (representados pelos *datasets* MMLU e GPQA).

## III. Metodologia

### A. Análise macro do processo de thinking

O diagrama a seguir apresenta o fluxo macro do pipeline de *thinking* proposto neste trabalho, oferecendo uma visão consolidada de todas as fases que o compõem.




Figura 1. Fluxo macro do pipeline de *thinking*.

O pipeline é iniciado a partir de um *prompt* de entrada fornecido pelo usuário. A partir desse insumo, o processo percorre as seguintes etapas organizadas em uma estrutura de ciclos aninhados (um loop dentro do outro): (i) definição dos critérios de aceitação da resposta final e do formato de saída esperado; (ii) decomposição do problema em tarefas atômicas e independentes; (iii) as tarefas criadas entram no **Micro Loop** de processamento (*Ciclo de Execução de Tarefas*), onde o sistema itera sobre cada tarefa pendente, resolvendo-a individualmente por meio de um ciclo interno inspirado no *Ralph Wiggum Loop*, até que todas sejam concluídas; (iv) após a execução, as informações resultantes de todas as tarefas são compiladas e submetidas ao **Macro Loop** de validação contínua, onde o compilado é avaliado frente aos critérios de aceitação globais previamente estabelecidos. Caso a avaliação indique que nem todos os critérios foram atendidos, o pipeline não descarta o trabalho realizado — em vez disso, identifica as lacunas e cria um plano adicional complementar com novas tarefas, retornando o fluxo para o *Micro Loop* de resolução. Este laço externo só é rompido quando todos os critérios são plenamente satisfeitos, culminando (v) na geração e composição da resposta final ao usuário. Esse arranjo de um

loop de execução localizado dentro de um loop maior de validação global confere ao sistema um caráter altamente iterativo e convergente.

Um aspecto central da arquitetura é a separação deliberada entre as fases de execução: cada etapa opera de forma *stateless* em relação às demais, no sentido de que não carrega diretamente o histórico de raciocínio das fases anteriores. Em vez disso, o sistema preserva apenas artefatos estruturados — em especial os arquivos `planning.json` e `tasks_results.json` — que funcionam como memória persistente e controlada entre as etapas. Essa decisão de projeto tem dois objetivos complementares: por um lado, mitigar os problemas de degradação discutidos na Introdução, nos quais o crescimento progressivo do contexto leva ao fenômeno frequentemente referido como *context rot* — o acúmulo de informação irrelevante, resumos implícitos e ruído que diluem o conteúdo útil e prejudicam a qualidade das respostas —; por outro, garantir que cada chamada ao LLM opere com o menor contexto possível, reduzindo o risco de que informações e raciocínios de tarefas anteriores contaminem a execução da tarefa corrente, introduzindo inconsistências ou “lixo de contexto” nas respostas geradas.

### B. Análise micro das fases

A seguir, cada fase do pipeline é detalhada individualmente. Para cada fase, são descritos: os agentes de LLM envolvidos, os dados de entrada e saída, e o fluxo de controle interno. Essa granularidade tem o objetivo de tornar o processo inteiramente replicável por pesquisadores externos.

#### B.1 Agentes de LLM


Neste trabalho, adota-se uma definição restrita de *agente*: trata-se de um componente composto exclusivamente por um *prompt* pré-definido e uma chamada ao modelo de linguagem (*LLM\_CALL*). Diferentemente de arquiteturas que atribuem a agentes acesso a ferramentas externas, chamadas a APIs, servidores MCP ou capacidades de navegação, os agentes aqui descritos operam de forma isolada — recebem um contexto de entrada estruturado, processam via LLM e retornam uma saída textual ou estruturada em JSON. Essa restrição é intencional: ao eliminar dependências externas, torna-se possível avaliar de forma mais direta o impacto da orquestração e do *prompting* sobre a qualidade das respostas, isolando as variáveis de interesse do estudo.

Todos os *prompts* de agentes são redigidos em inglês. Estudos como *Beyond English: Evaluating Multilingual Capabilities of Large Language Models* [14] e *Language Models are Multilingual Chain-of-Thought Reasoners* [15] mostram que modelos de linguagem multilíngues tendem a produzir resultados de maior qualidade quando instruídos no idioma em que foram mais amplamente treinados — predominantemente o inglês —, independentemente do idioma da questão de entrada. O trabalho *Cross-lingual Prompting: Enhancing Multilingual Capabilities of Large Language Models* [16] reforça esse achado ao demonstrar que a combinação de *prompting* em inglês com raciocínio

*zero-shot* em cadeia produz ganhos consistentes mesmo em línguas de menor representação nos dados de treinamento. A adoção do inglês como idioma padrão dos *prompts* de agentes visa, portanto, maximizar a qualidade do raciocínio interno do modelo, sem prejuízo ao idioma da resposta entregue ao usuário — que é determinado separadamente, conforme descrito na seção seguinte.

Adicionalmente, todos os *prompts* são construídos utilizando a sintaxe *Markdown*, com delimitadores explícitos de seção para separar instruções gerais, contexto de entrada e especificações de saída. Estudos como *The Impact of Prompt Formatting on Large Language Model Performance* [17] e *Beyond Prompt Content: Enhancing LLM Performance via Content-Format Integrated Prompt Optimization* [18] mostram que a formatação do *prompt* afeta de forma mensurável o desempenho dos modelos, e que otimizações conjuntas de conteúdo e formato produzem ganhos adicionais sobre a otimização exclusiva do conteúdo textual. A adoção de *Markdown* visa, portanto, tornar delimitadores, hierarquias e restrições mais salientes durante a inferência, contribuindo para respostas mais consistentes com as instruções fornecidas.

#### B.2 Definição dos critérios de aceite da resposta final



**Figura 2.** Fase de definição dos critérios de aceite da resposta final.

Esta fase é responsável por transformar o *prompt* bruto do usuário em dois artefatos que guiarão todo o processo posterior: (i) uma lista de critérios de aceitação que a resposta final deverá satisfazer, e (ii) uma especificação



do formato de saída esperado. Para isso, dois agentes são acionados em sequência a partir da mesma entrada.

O `acceptance_criteria_agent` recebe o *prompt* de entrada do usuário e é responsável por identificar e listar, de forma explícita, os critérios objetivos e verificáveis que uma resposta satisfatória deve cumprir. Em seguida, o `expected_output_format_agent` analisa o mesmo *prompt*, buscando por indicações explícitas de formato de saída — como “retorne somente a alternativa correta”, “responda em JSON” ou “elabore uma justificativa”. Caso nenhuma indicação seja encontrada, o agente infere o formato mais adequado ao tipo de tarefa: para questões de múltipla escolha, o padrão é “retornar somente a letra da alternativa correta, sem explicações adicionais”; para questões abertas, “texto corrido em formato Markdown”. O idioma da resposta final é tratado como parte integrante do formato de saída: se o usuário o especificou explicitamente, essa instrução é acatada; caso contrário, o agente infere o idioma a partir do idioma utilizado na entrada e o registra como especificação. Quando exemplos de saída são fornecidos pelo usuário, estes são incorporados ao campo correspondente.

Os resultados dessas duas chamadas são então consolidados em um arquivo JSON denominado `planning.json`, que servirá de artefato central de memória estruturada para todas as fases subsequentes. A estrutura do `planning.json` é inspirada no `prd.json` do *Ralph Wiggum Loop* original, porém estendida para incorporar as informações de critérios de aceitação e formato de saída.

```
{
  "general_infos": {
    "acceptance_criteria": [],
    "expected_output_format": {
      "format": "",
      "response_language": ""
    }
  },
  "tasks": []
}
```

O campo `tasks` é inicialmente vazio e será preenchido pela fase seguinte. A separação entre `general_infos` e `tasks` é proposital: as informações gerais são invariantes ao longo de todo o pipeline, enquanto as tarefas podem ser adicionadas iterativamente por planos complementares.

### B.3 Quebra de Tasks Independentes




Figura 3. Fase de quebra de tarefas independentes.

Esta fase é, em termos de responsabilidade lógica, a mais crítica de todo o pipeline: é aqui que se implementa o princípio central do *Ralph Wiggum Loop* — a decomposição do problema em unidades mínimas e independentes de execução. O agente `atomic_tasks_planner_agent` recebe como entrada o *prompt* do usuário e o campo `general_infos` do `planning.json` gerado na fase anterior, e a partir disso constrói um plano de tarefas atômicas.

O conceito de atomicidade empregado é preciso: uma tarefa é considerada atômica quando representa a menor unidade de trabalho possível e pode ser executada e avaliada de forma completamente independente das demais tarefas do plano, sem necessidade de acessar ou reutilizar os resultados de outras tarefas durante sua própria execução.

Essa propriedade é fundamental para garantir o funcionamento correto do mecanismo de *fresh context* — se tarefas dependessem umas das outras durante a execução, seria necessário carregar contexto acumulado, o que reintroduziria os problemas de degradação que a arquitetura busca mitigar.


Após a geração do plano inicial, o agente `atomic_tasks_revisor_agent` é acionado para verificar se todas as tarefas propostas satisfazem o critério de independência, retornando um JSON com um campo booleano de aprovação e uma justificativa. Se problemas forem identificados, o agente `atomic_tasks_rewriter_agent` — que incorpora em seu *prompt* todas as regras e restrições do planejador — é acionado para reescrever o plano com base na justificativa fornecida. Esse ciclo de revisão repete-se até que o revisor valide o plano, garantindo que apenas tarefas verdadeiramente independentes avancem para a fase de execução.

Cada tarefa do plano é representada no `planning.json` no seguinte formato:

```
{
  "id": "",
  "title": "",
  "description": "",
  "acceptance_criteria": [],
  "pass_phase": false
}
```

O campo `pass_phase` é inicializado como `false` para todas as tarefas e atualizado para `true` ao final da execução bem-sucedida de cada uma, funcionando como marcador de progresso para o mecanismo iterativo.

#### B.4 Resolução das tarefas — Ralph Loop



**Figura 4.** Resolução iterativa das tarefas utilizando o Ralph Loop.

Esta fase implementa o núcleo iterativo do *Ralph Wiggum Loop* adaptado ao contexto deste trabalho. O

processo inicia pela verificação do `planning.json`: enquanto existirem tarefas com `pass_phase: false`, o pipeline seleciona a próxima tarefa pendente e inicia um ciclo de tentativa–avaliação–revisão.

Cada iteração do ciclo consiste em: (i) uma chamada ao LLM contendo exclusivamente o conteúdo da tarefa atual — sem histórico acumulado de outras tarefas —, seguida de (ii) uma chamada ao agente `task_outcome_reviewer_agent`, que compara a resposta gerada com os `acceptance_criteria` da tarefa. O revisor retorna um JSON com um campo booleano de aprovação e uma justificativa. Se o revisor aprovar a resposta, ela é salva no arquivo `tasks_results.json` e o campo `pass_phase` da tarefa é atualizado para `true`. Se reprovar, a justificativa é incorporada à próxima chamada ao LLM, configurando um ciclo de refinamento guiado, análogo aos mecanismos de *Reflexion* [5] e *Self-Debugging* [6].

No que diz respeito à persistência dos resultados, adota-se uma adaptação do princípio original do *Ralph Wiggum Loop*, que preconiza que “All memory lives in files and git — not the model”. Como o presente trabalho aplica o pipeline a cenários distintos do desenvolvimento de software, o mecanismo de *commit* em repositório Git é substituído pelo arquivo `tasks_results.json`, que acumula exclusivamente as respostas finais aprovadas de cada tarefa — sem registrar histórico de raciocínio, tentativas anteriores ou qualquer metadado do ciclo iterativo.

Para mitigar o risco de *deadlock*, implementa-se um mecanismo de controle denominado *pânico*. Um contador `task_interactions` é incrementado a cada chamada ao LLM dentro do ciclo de uma tarefa. Quando esse contador atinge o valor de `max_iterations`, a fase encerra automaticamente e a resposta disponível no momento é salva no `tasks_results.json`, mesmo que os critérios não tenham sido plenamente atendidos.

## B.5 Avaliação dos critérios de aceitação





Figura 5. Avaliação global dos critérios de aceitação.

Ao término da resolução de todas as tarefas do plano, o pipeline consolida os resultados armazenados no `tasks_results.json` e os submete a uma avaliação global frente aos critérios de aceitação definidos em `general_infos.acceptance_criteria` do `planning.json`. Essa fase é executada pelo agente `final_response_acceptance_criteria_reviewer_agent`, que recebe ambos os artefatos como entrada.

A lógica é análoga à dos revisores de tarefa individual, porém operando em um nível de abstração superior: em vez de avaliar uma resposta pontual contra critérios locais de uma tarefa, o agente avalia se o conjunto total de resultados gerados fornece insumos suficientes para construir uma resposta final que atenda a todos os critérios globais. Dois fluxos de saída são possíveis a partir dessa avaliação: caso todos os critérios sejam considerados atendidos, o pipeline avança para a criação da resposta final; caso contrário, avança para a criação de um plano adicional complementar.

## B.6 Criação de plano complementar




**Figura 6.** Criação de plano complementar para critérios não atendidos.

Quando a avaliação global indica que os critérios de aceitação não foram plenamente atendidos, o pipeline não retorna ao início — o que implicaria descartar e reprocessar etapas já concluídas. Em vez disso, adota-se uma estratégia de afunilamento progressivo: o agente `acceptance_gap_prompt_creator` analisa a justificativa retornada pelo revisor global e produz um novo *prompt* no estilo de entrada de usuário, descrevendo exclusivamente o que ainda precisa ser resolvido para cobrir as lacunas identificadas.

Esse *prompt* é então submetido ao `atomic_tasks_planner_agent`, o mesmo agente da fase de quebra de tarefas independentes, que gera um novo conjunto de tarefas complementares. Essas novas tarefas são concatenadas ao campo `tasks` do `planning.json` original, e o pipeline retorna à fase de resolução das tarefas para executá-las.

Esse mecanismo constitui, na prática, um segundo nível de loop que garante a convergência iterativa do pipeline: a cada ciclo, o conteúdo gerado aproxima-se do que é necessário para satisfazer todos os critérios de aceitação, sem desperdiçar o trabalho já realizado nas iterações anteriores.

## B.7 Criação da resposta final



**Figura 7.** Fase de composição da resposta final.

A fase de criação da resposta final assume que o `tasks_results.json` contém todos os insumos necessários para compor uma resposta que satisfaça integralmente os critérios de aceitação globais — premissa garantida pela fase de avaliação anterior. É nesta fase, e somente nesta, que o conteúdo do `tasks_results.json` é efetivamente recuperado e utilizado.

O agente `final_response_composer_agent` recebe como entrada o arquivo completo de resultados, o campo `general_infos.expected_output_format` do `planning.json` e o *prompt* original do usuário, utilizando-os em conjunto para compor a resposta final no formato e idioma especificados. O retorno desse agente é a saída direta do pipeline ao usuário, encerrando o processo de *thinking*.

## IV. Plano de avaliação

O plano de avaliação visa mensurar o impacto da arquitetura de orquestração na acurácia de modelos de linguagem em tarefas de raciocínio geral, comparando sistematicamente a inferência direta com a orquestrada. Para essa validação, a metodologia contempla cinco modelos selecionados para cobrir uma progressão de complexidade: Llama 3.1 (8B, 70B e 405B), Claude Sonnet 4.6 e GPT 5.4.

Para cada modelo, está prevista a comparação de duas configurações: (i) uma inferência "linear", realizada por meio de uma requisição direta ao modelo sem processamento auxiliar, e (ii) a mesma inferência mediada pelo *Harness* proposto, empregando ciclos de verificação e ferramentas externas. O desempenho será medido por meio de 180 questões amostradas das bases *GPQA* [19], *MMLU* [20] e *MMLU-Pro* [21], escolhidas por seu elevado rigor acadêmico. A métrica primária consistirá na acurácia, obtida pela correspondência estrita entre a alternativa final selecionada pelo sistema e o gabarito.

A execução seguirá um protocolo no qual, inicialmente, os modelos estabelecem seu desempenho de base na inferência padrão. Na sequência, as métricas serão reavaliadas sob a arquitetura orquestrada (inicialmente focada na família Llama), sempre respeitando restrições operacionais *stateless*. O objetivo esperado desta avaliação é



verificar se o *harness* altera o posicionamento dos modelos no ranking global, testando a hipótese de que a orquestração estruturada suplanta ganhos atrelados puramente à escala de parâmetros.

A Tabela I apresenta as posições relativas esperadas no ranking de desempenho, ilustrando o posicionamento hipotético de cada configuração.

**Tabela I.** Posição esperada no ranking de desempenho por modelo e configuração (hipotético, para fins de planejamento).

| Modelo            | Configuração | Posição Esperada |
|-------------------|--------------|------------------|
| Llama 3.1 8B      | Direto       | 8º               |
| Llama 3.1 70B     | Direto       | 7º               |
| Llama 3.1 8B      | Ralph Loop   | 6º               |
| Llama 3.1 405B    | Direto       | 5º               |
| Llama 3.1 70B     | Ralph Loop   | 4º               |
| Claude Sonnet 4.6 | Direto       | 3º               |
| Llama 3.1 405B    | Ralph Loop   | 2º               |
| GPT 5.4           | Direto       | 1º               |

## V. Glossário de Termos

### A. Termos citados

**LLM (Large Language Model):** Modelo de inteligência artificial treinado em grandes volumes de texto para compreensão e geração de linguagem natural.  
[https://en.wikipedia.org/wiki/Large\\_language\\_model](https://en.wikipedia.org/wiki/Large_language_model)

**Ralph Wiggum Loop:** Paradigma arquitetural de orquestração *stateless* que isola a execução de tarefas em etapas rigidamente separadas. Reinicializa o contexto a cada iteração (*Fresh Context*), persistindo apenas as informações intermediárias essenciais em arquivos para evitar a degradação de histórico.  
<https://ghuntley.com/specs/ralph/>

**Harness (Orquestração):** Estrutura lógica e regras de governança que envolvem um modelo base para guiar seu processo de inferência e interação com ferramentas. Variações nessas estruturas arquiteturais podem causar impactos substanciais no desempenho de agentes, conceito também explorado na literatura recente em publicações como *Nonstandard Errors in AI Agents*.  
<https://arxiv.org/abs/2603.16744>

### B. Ferramentas citadas

**Cloud Code:** Interface de linha de comando (CLI) focada em desenvolvimento assistido por IA, oferecendo forte integração a modelos da família Anthropic.  
<https://www.anthropic.com/>

**Codex:** Modelo de linguagem e ferramenta desenvolvidos pela OpenAI especialmente otimizados para tarefas de geração e compreensão de sintaxe de código de programação.  
<https://openai.com/>

**OpenCLI:** Interface de linha de comando de código aberto desenvolvida para facilitar a conexão e interação técnica com diferentes provedores de modelos de linguagem.  
<https://opencli.ai/>

## VI. Referências

- [1] T. B. Brown et al., “Language Models are Few-Shot Learners,” em *Advances in Neural Information Processing Systems*, 2020.
- [2] J. Wei et al., “Chain-of-Thought Prompting Elicits Reasoning in Large Language Models,” *arXiv preprint arXiv:2201.11903*, 2022.
- [3] S. Yao et al., “Tree of Thoughts: Deliberate Problem Solving with Large Language Models,” *arXiv preprint arXiv:2305.10601*, 2023.
- [4] S. Yao et al., “ReAct: Synergizing Reasoning and Acting in Language Models,” *arXiv preprint arXiv:2210.03629*, 2022.
- [5] N. Shinn, F. Cassano, B. Labash, A. Gopinath, K. Narasimhan e S. Yao, “Reflexion: Language Agents with Verbal Reinforcement Learning,” *arXiv preprint arXiv:2303.11366*, 2023.
- [6] X. Chen, M. Lin, N. Schärli e D. Zhou, “Teaching Large Language Models to Self-Debug,” *arXiv preprint arXiv:2304.05128*, 2023.
- [7] A. Madaan et al., “Self-Refine: Iterative Refinement with Self-Feedback,” *arXiv preprint arXiv:2303.17651*, 2023.
- [8] D. Zhou et al., “Least-to-most prompting enables complex reasoning in large language models,” *arXiv preprint arXiv:2205.10625*, 2022.
- [9] T. Khot et al., “Decomposed prompting: A modular approach for solving complex tasks,” *arXiv preprint arXiv:2210.02406*, 2022.
- [10] L. Wang et al., “Plan-and-solve prompting: Improving zero-shot chain-of-thought reasoning by large language models,” *arXiv preprint arXiv:2305.04091*, 2023.
- [11] N. F. Liu et al., “Lost in the middle: How language models use long contexts,” *Transactions of the Association for Computational Linguistics*, v. 12, pp. 277–294, 2024.
- [12] G. Ghuntley, *Ralph Loop: A Structured Orchestration Pattern for LLM Inference*, Online. Disponível em: <https://ghuntley.com/specs/ralph/>, Acesso em: abr. 2026, 2025.
- [13] C. McComb et al., “Supervising Ralph Wiggum: Exploring a Metacognitive Co-Regulation Agentic AI Loop for Engineering Design,” *arXiv preprint arXiv:2603.24768*, 2026.
- [14] Y. Huang et al., “Beyond English: Evaluating Multilingual Capabilities of Large Language Models,” *arXiv preprint arXiv:2401.00000*, 2024.

- [15] F. Shi, M. Suzgun, M. Freitag, X. Wang, M. Surdeanu e J. Wei, “Language Models are Multilingual Chain-of-Thought Reasoners,” em *International Conference on Learning Representations*, 2023.
- [16] C. Qin et al., “Cross-lingual Prompting: Enhancing Multilingual Capabilities of Large Language Models,” *arXiv preprint arXiv:2302.00000*, 2023.
- [17] X. He et al., “The Impact of Prompt Formatting on Large Language Model Performance,” *arXiv preprint arXiv:2403.00000*, 2024.
- [18] Y. Liu et al., “Beyond Prompt Content: Enhancing LLM Performance via Content-Format Integrated Prompt Optimization,” *arXiv preprint arXiv:2502.04295*, 2025.
- [19] D. Rein et al., “GPQA: A Graduate-Level Google-Proof Q&A Benchmark,” *arXiv preprint arXiv:2311.12022*, 2023.
- [20] D. Hendrycks et al., “Measuring Massive Multitask Language Understanding,” em *International Conference on Learning Representations*, 2021.
- [21] Y. Wang et al., “MMLU-Pro: A More Robust and Challenging Multi-Task Language Understanding Benchmark,” *arXiv preprint arXiv:2406.01574*, 2024.